Детерминированные алгоритмы аппроксимации первых слоёв LLM

Чанкаев Шамиль, Мархабаев Бекет

Аннотация

Первые слои больших языковых моделей (LLM) на основе архитектуры Transformer [2] выполняют сравнительно простые операции: восстанавливают статистику биграмм и коротких n-грамм [1], реализуют фиксированные позиционные паттерны внимания и хранят поверхностные шаблоны в слоях прямого распространения [3]. Мы исследуем гипотезу о том, что вычисления первых k слоёв можно заменить *детерминированными* алгоритмами, то есть процедурами без случайной выборки и без дообучения градиентным спуском, которые строятся по весам модели и статистике калибровочного корпуса в замкнутой форме. Мы адаптируем к каузальному декодеру Qwen3 методы эффективного внимания и сжатия слоёв MLP из литературы и предлагаем собственные: факторизацию внимания «позиционное ядро × значимость ключевого токена», типизированную замену голов, линеаризацию MLP с компенсацией дрейфа остаточного потока и табличные замены блоков. Эксперименты проводятся на Qwen3-0.6B и 1.7B (Base) с оценкой по KL-дивергенции к исходной модели, perplexity и стандартным бенчмаркам. Профилирование показывает, что первые слои образуют отдельный режим «до стока внимания»: массивная активация первого токена и сток внимания возникают лишь после нескольких первых слоёв, что задаёт естественную глубину замены k_{sink}. Мы также показываем, что рандомизированные признаки FAVOR+ (Performer [14]) неприменимы к первым слоям без переобучения: нормы ключей после QK-нормализации лежат далеко за пределами области, где их оценка ядра устойчива. Основные результаты. (1) Внимание первых трёх слоёв заменяется окном из 64 позиций со стоком с ростом perplexity 1.5–1.8 % и без потерь на семи бенчмарках; MLP первых слоёв заменяется хуже: лучший метод — предложенный детерминированный предиктор активных нейронов — стоит 4.7 % (0.6B) и 1.7 % (1.7B) при четверти вычислений MLP, а по карте заменяемости MLP ранних слоёв оказываются самыми незаменимыми в модели. (2) Мы обнаруживаем ловушку калибровки в замкнутой форме: единичные токены с массивной активацией доминируют в задаче наименьших квадратов, ошибка ложится в каналы стока внимания и обрушивает модель; мы даём формулу влияния строки, воспроизводим эффект дозой отравленных окон и устраняем его исключением строк-выбросов, а также показываем, что массивную активацию создают один–пять нейронов, удаление которых разрушает модель. (3) Априорные статистики слоя предсказывают KL его замены с ранговой корреляцией 0.9–0.97 и позволяют планировать замены на непросмотренной модели в 10–15 раз точнее замены префикса. (4) На втором семействе (SmolLM2-1.7B, Llama-3.2-1B) сток оказывается привязан не к позиции, а к токену: один нейрон создаёт массивную активацию на «the» в любой позиции, и замены переносятся лишь с защитой таких нейронов и хранением таких ключей (окно: 64 → 4 % PPL при $k = 8$); MLP

первых слоёв у этого семейства заменяется хуже, а планировщик переносится. Результаты дополняют дискуссию о том, насколько внутренние вычисления обученных сетей «уже чисты» и поддаются явному описанию [6, 7].

Ключевые слова: трансформеры, большие языковые модели, аппроксимация внимания, механистическая интерпретируемость, детерминированные алгоритмы, низкоранговые приближения, сжатие MLP.

1 Введение

Архитектура Transformer [2] стала основой современных больших языковых моделей. Её центральный механизм, самовнимание (self-attention), требует $O(n^2)$ операций по длине последовательности n. Это породило большое семейство методов эффективной аппроксимации внимания. Их можно условно разделить на несколько групп:

- **ядерные и линейные** методы, в которых softmax заменяется скалярным произведением признаковых отображений: линейное внимание [11], Performer со случайными признаками FAVOR+ [14], случайные фурье-признаки RFA [15], SOFT без softmax [16];
- **низкоранговые** методы: проекции Linformer по оси последовательности [12], приближение Нистрёма в Nyströmformer [13], аналитический фреймворк A3 [22];
- **разреженные** шаблоны внимания: Sparse Transformer [17], хеширование LSH в Reformer [18], комбинация локального, глобального и случайного внимания в BigBird [19];
- **замена внимания** фиксированным или синтезированным смешиванием токенов: преобразование Фурье в FNet [20], Synthesizer [21].

Почти все эти методы аппроксимируют механизм внимания *равномерно по глубине*: одна и та же схема применяется во всех слоях и, как правило, требует обучения модели с нуля или дообучения. При этом многие из них по своей природе *стохастичны*: случайные признаки, случайные хеш-функции, случайные рёбра графа внимания. Из-за этого ошибка аппроксимации зависит от выборки, а результат вычислений воспроизводим лишь с точностью до зерна генератора.

Параллельно развивается механистическая интерпретируемость: она показывает, что слои трансформера неоднородны по своей функции [8, 25]. Математический анализ трансформерных схем [1] показывает, что модель без слоёв внимания приближает статистику биграмм. Однослойная модель, состоящая только из внимания, дополнительно реализует «skip-trigram»-зависимости. Индукционные головы, которые обеспечивают обучение в контексте, возникают лишь при композиции как минимум двух слоёв внимания [23]. Слои прямого распространения работают как память «ключ–значение», причём ключи нижних слоёв реагируют на поверхностные шаблоны (конкретные n-граммы), а верхних — на семантические [3]. Словарное обучение на активациях MLP небольшой модели выделяет интерпретируемые моносемантические признаки [24]. Известно также, что многоголовое самовнимание

способно выражать свёрточные слои [4]. Значит, локальные позиционные паттерны внимания в принципе описываются фиксированными ядрами. Наконец, теоретический анализ показывает, что чистое внимание без остаточных связей и MLP вырождается по рангу дважды экспоненциально с глубиной [5]. Поэтому остаточный поток играет ключевую роль при любой послойной замене вычислений. Отдельно идёт дискуссия о том, являются ли обученные нейросети «уже чистыми» (*already clean*), то есть поддающимися явному описанию [6, 7, 9, 10]. Cammarata [6] утверждает, что видимая полисемантичность нейронов в основном объясняется не суперпозицией, а «рекурсивным обобщением» связанных понятий, и по предварительной оценке около 90% «полюсов» нейронов Qwen3-32B (положительная или отрицательная сторона активации) имеют одну основную функцию. Gao [7] возражает, что совпадения активирующих примеров с шаблоном недостаточно, и предлагает строгий критерий: объяснение верно, если подстановка смоделированных по нему активаций не увеличивает KL-дивергенцию выходного распределения модели. Именно этот критерий — KL при подстановке — мы используем как основную метрику замены слоёв.

Эти наблюдения подсказывают иную постановку задачи. Если первые слои LLM реализуют в основном локальные, «поверхностные» вычисления, то их можно заменить *явными детерминированными алгоритмами* вместо единообразной аппроксимации внимания во всей сети. Под детерминированным алгоритмом мы понимаем процедуру, которая

1. не использует случайную выборку на этапе вывода;
2. строится по весам обученной модели и/или статистике корпуса в замкнутом виде или явной процедурой, без градиентного дообучения;
3. даёт одинаковый выход на одинаковом входе и допускает аналитическую оценку ошибки.

Примеры таких алгоритмов: фиксированные разреженные шаблоны внимания, позиционные ядра вместо голов внимания, таблицы поиска по токенам, аналитические низкоранговые разложения матриц W_{QK}, W_{OV} и весов MLP [22, 26, 27], линейные карты, подогнанные гребневой регрессией.

Постановка задачи. Пусть $f = f_L \circ \cdots \circ f_1 \circ E$ — языковая модель из L блоков с матрицей эмбеддингов E, а $h_k(x)$ — состояние остаточного потока после k-го блока на входе x. Требуется построить детерминированный алгоритм A_k, такой что

$$\tilde{f} = f_L \circ \cdots \circ f_{k+1} \circ A_k, \qquad \mathbb{E}_x \, \mathrm{KL}\big(p_f(\cdot \mid x) \,\|\, p_{\tilde{f}}(\cdot \mid x)\big) \le \varepsilon,$$

и определить максимальную глубину $k^*(\varepsilon)$, для которой это возможно при ограничениях на вычислительную сложность и память алгоритма A_k.

Вклад работы.

1. Формализация задачи детерминированной аппроксимации первых k слоёв LLM с критерием качества «KL при подстановке» и протокол, в котором исходная и изменённая модели сравниваются в одном процессе в fp32 (шум bf16 сам по себе даёт KL$\approx 10^{-3}$).

2. Адаптация к каузальному декодеру с GQA, QK-нормализацией и RoPE шести методов эффективного внимания и пяти методов сжатия MLP из литературы; разбор того, почему Linformer, Nyströmformer, FNet, SOFT и Reformer неприменимы без переобучения.

3. Новые детерминированные методы: факторизация внимания «позиционное ядро × значимость ключевого токена» (O4), типизированная замена голов (O1), ридж-свёртка вместо внимания (O2), аддитивная n-граммная замена блоков (O3), линеаризация MLP с точными нейронами (M-O1), табличный (M-O2) и кусочно-линейный (M-O3) MLP. Все наши методы калибруются последовательно с компенсацией накопленного дрейфа.

4. Послойный профиль Qwen3-0.6B и 1.7B, выделяющий режим «до стока внимания» и задающий глубину k_{sink}, и анализ неприменимости случайных признаков к первым слоям.

5. Сравнение по KL, perplexity и семи бенчмаркам на двух размерах модели, кривые «качество – бюджет вычислений», доверительные интервалы и дистилляционный контроль. Итог: внимание первых трёх слоёв заменяется окном со стоком за 1.5–1.8 % PPL без потерь на бенчмарках; MLP первых слоёв — лишь частично, лучший метод — наш предиктор активных нейронов M-O4 (4.7 % на 0.6B, 1.7 % на 1.7B при четверти вычислений MLP).

6. Ловушка калибровки в замкнутой форме: единичные токены с массивной активацией доминируют в задаче наименьших квадратов и обрушивают модель на слое, где возникает сток внимания. Мы даём формулу влияния строки, воспроизводим эффект дозой отравленных окон, устраняем его исключением строк-выбросов и показываем, какие опубликованные методы ему не подвержены и почему.

7. Нейроны стока: массивную активацию создают один–пять нейронов MLP, без которых модель не работает; их сохранение — обязательное условие любого отбора нейронов в ранних слоях.

8. Карта заменяемости по глубине и априорный критерий: дешёвые статистики слоя предсказывают KL его замены с ранговой корреляцией 0.9–0.97, воспроизводятся на второй модели и позволяют планировать замены на непросмотренной модели в 10–15 раз точнее замены префикса.

Структура статьи. Раздел 2 содержит обзор литературы. В разделе 3 описаны постановка, адаптированные методы из литературы и предложенные методы. Раздел 4 описывает экспериментальную установку, раздел 5 — результаты, раздел 6 — обсуждение и ограничения.

Список литературы

[1] N. Elhage et al. A Mathematical Framework for Transformer Circuits. Transformer Circuits Thread, 2021. `https://transformer-circuits.pub/2021/framework/index.html`

[2] A. Vaswani et al. Attention Is All You Need. NeurIPS, 2017. arXiv:1706.03762.

[3] M. Geva et al. Transformer Feed-Forward Layers Are Key-Value Memories. EMNLP, 2021. arXiv:2012.14913.

[4] J.-B. Cordonnier et al. On the Relationship between Self-Attention and Convolutional Layers. ICLR, 2020. arXiv:1911.03584.

[5] Y. Dong et al. Attention is Not All You Need: Pure Attention Loses Rank Doubly Exponentially with Depth. ICML, 2021. arXiv:2103.03404.

[6] N. Cammarata. Neural Networks Are Already Clean. Goodfire, 2026. https://already-clean.goodfire.com/

[7] L. Gao. Neural networks are not already clean. LessWrong, 2026. https://www.lesswrong.com/posts/Dkh7pXKjoNWkkxQDz/neural-networks-are-not-already-clean

[8] C. Olah et al. Zoom In: An Introduction to Circuits. Distill, 2020. https://distill.pub/2020/circuits/zoom-in/

[9] M. Lissack. Already Clean, Not Yet Meaningful: One "how" for the question Cammarata has opened. PhilArchive. https://philarchive.org/rec/LISACN

[10] S. Brodsky. Is AI easier to understand than scientists thought? IBM Think, 2026. https://www.ibm.com/think/news/is-ai-easier-to-understand-than-scientists-thought-goodfire-essay

[11] A. Katharopoulos et al. Transformers are RNNs: Fast Autoregressive Transformers with Linear Attention. ICML, 2020. arXiv:2006.16236.

[12] S. Wang et al. Linformer: Self-Attention with Linear Complexity, 2020. arXiv:2006.04768.

[13] Y. Xiong et al. Nyströmformer: A Nyström-Based Algorithm for Approximating Self-Attention. AAAI, 2021. arXiv:2102.03902.

[14] K. Choromanski et al. Rethinking Attention with Performers. ICLR, 2021. arXiv:2009.14794.

[15] H. Peng et al. Random Feature Attention. ICLR, 2021. arXiv:2103.02143.

[16] J. Lu et al. SOFT: Softmax-free Transformer with Linear Complexity. NeurIPS, 2021. arXiv:2110.11945.

[17] R. Child et al. Generating Long Sequences with Sparse Transformers, 2019. arXiv:1904.10509.

[18] N. Kitaev et al. Reformer: The Efficient Transformer. ICLR, 2020. arXiv:2001.04451.

[19] M. Zaheer et al. Big Bird: Transformers for Longer Sequences. NeurIPS, 2020. arXiv:2007.14062.

[20] J. Lee-Thorp et al. FNet: Mixing Tokens with Fourier Transforms. NAACL, 2022. arXiv:2105.03824.

[21] Y. Tay et al. Synthesizer: Rethinking Self-Attention in Transformer Models. ICML, 2021. arXiv:2005.00743.

[22] J. T. H. Wong et al. A3: an Analytical Low-Rank Approximation Framework for Attention, 2025. arXiv:2505.12942.

[23] C. Olsson et al. In-context Learning and Induction Heads. Transformer Circuits Thread, 2022. arXiv:2209.11895.

[24] T. Bricken et al. Towards Monosemanticity: Decomposing Language Models With Dictionary Learning. Transformer Circuits Thread, 2023. `https://transformer-circuits.pub/2023/monosemantic-features/index.html`

[25] D. Rai et al. A Practical Review of Mechanistic Interpretability for Transformer-Based Language Models, 2024. arXiv:2407.02646.

[26] Z. Yuan et al. ASVD: Activation-aware Singular Value Decomposition for Compressing Large Language Models, 2023. arXiv:2312.05821.

[27] X. Wang et al. SVD-LLM: Truncation-aware Singular Value Decomposition for Large Language Model Compression. ICLR, 2025. arXiv:2403.07378.

[28] Z. Liu et al. Deja Vu: Contextual Sparsity for Efficient LLMs at Inference Time. ICML, 2023. arXiv:2310.17157.

[29] Z. Zhang et al. MoEfication: Transformer Feed-forward Layers are Mixtures of Experts. Findings of ACL, 2022. arXiv:2110.01786.

[30] J.-Y. Lee et al. CATS: Contextually-Aware Thresholding for Sparsity in Large Language Models. COLM, 2024. arXiv:2404.08763.

[31] J. Liu et al. Training-Free Activation Sparsity in Large Language Models. ICLR, 2025. arXiv:2408.14690.

[32] D. Shopkhoev et al. ReplaceMe: Network Simplification via Depth Pruning and Transformer Block Linearization. NeurIPS, 2025. arXiv:2505.02819.

[33] V.-D. Yun et al. Ghosted Layers: Unconstrained Activation Alignment for Recovering Layer-Pruned LLMs. ICML, 2026. arXiv:2605.15491.

[34] M. Yu et al. The Super Weight in Large Language Models. arXiv:2411.07191, 2024.

[35] M. Sun et al. Massive Activations in Large Language Models. COLM, 2024. arXiv:2402.17762.

[36] S. Merity, C. Xiong, J. Bradbury, R. Socher. Pointer Sentinel Mixture Models. ICLR, 2017. arXiv:1609.07843. Набор WikiText: `https://huggingface.co/datasets/Salesforce/wikitext`

[37] L. Gao et al. The Pile: An 800GB Dataset of Diverse Text for Language Modeling. 2020. arXiv:2101.00027. Подвыборка pile-10k: `https://huggingface.co/datasets/NeelNanda/pile-10k`

[38] L. Gao et al. A framework for few-shot language model evaluation (lm-evaluation-harness), v0.4. Zenodo, 2023. `https://github.com/EleutherAI/lm-evaluation-harness`

[39] D. Paperno et al. The LAMBADA dataset: Word prediction requiring a broad discourse context. ACL, 2016.

[40] R. Zellers, A. Holtzman, Y. Bisk, A. Farhadi, Y. Choi. HellaSwag: Can a Machine Really Finish Your Sentence? ACL, 2019.

[41] P. Clark et al. Think you have Solved Question Answering? Try ARC, the AI2 Reasoning Challenge. 2018. arXiv:1803.05457.

[42] Y. Bisk, R. Zellers, R. Le Bras, J. Gao, Y. Choi. PIQA: Reasoning about Physical Commonsense in Natural Language. AAAI, 2020.

[43] K. Sakaguchi, R. Le Bras, C. Bhagavatula, Y. Choi. WinoGrande: An Adversarial Winograd Schema Challenge at Scale. AAAI, 2020.

[44] D. Hendrycks et al. Measuring Massive Multitask Language Understanding. ICLR, 2021. arXiv:2009.03300.