Детерминированные алгоритмы аппроксимации первых слоёв LLM

[TODO: авторы]

Аннотация

Первые слои больших языковых моделей (LLM) на основе архитектуры Transformer [2] выполняют сравнительно простые операции: восстанавливают статистику биграмм и коротких n-грамм [1], реализуют фиксированные позиционные паттерны внимания и хранят поверхностные шаблоны в слоях прямого распространения [3]. Мы исследуем гипотезу о том, что вычисления первых k слоёв можно заменить *детерминированными* алгоритмами, то есть процедурами без случайной выборки и без дообучения градиентным спуском: таблицами поиска по контексту ограниченной длины, фиксированными разреженными и свёрточными ядрами внимания, а также аналитическими низкоранговыми приближениями. В отличие от рандомизированных методов эффективного внимания (Performer [14], RFA [15], Reformer [18]) такие аппроксимации воспроизводимы и допускают явный анализ ошибки. Мы предлагаем [TODO: семейство алгоритмов / название метода], оцениваем его на моделях [TODO: GPT-2, Pythia, ...] и определяем глубину k^*, до которой замена слоёв сохраняет качество модели: [TODO: основной количественный результат, например рост perplexity не более X% при замене первых k^* слоёв]. Результаты дополняют дискуссию о том, насколько внутренние вычисления обученных сетей «уже чисты» и поддаются явному описанию [6, 7].

Ключевые слова: трансформеры, большие языковые модели, аппроксимация внимания, механистическая интерпретируемость, детерминированные алгоритмы, низкоранговые приближения.

1 Введение

Архитектура Transformer [2] стала основой современных больших языковых моделей. Её центральный механизм, самовнимание (self-attention), требует $O(n^2)$ операций по длине последовательности n. Это породило большое семейство методов эффективной аппроксимации внимания. Их можно условно разделить на несколько групп:

- **ядерные и линейные** методы, в которых softmax заменяется скалярным произведением признаковых отображений: линейное внимание [11], Performer со случайными признаками FAVOR+ [14], случайные фурье-признаки RFA [15], SOFT без softmax [16];
- **низкоранговые** методы: проекции Linformer по оси последовательности [12], приближение Нистрёма в Nyströmformer [13], аналитический фреймворк A3 [22];

- **разреженные** шаблоны внимания: Sparse Transformer [17], хеширование LSH в Reformer [18], комбинация локального, глобального и случайного внимания в BigBird [19];

- **замена внимания** фиксированным или синтезированным смешиванием токенов: преобразование Фурье в FNet [20], Synthesizer [21].

Почти все эти методы аппроксимируют механизм внимания *равномерно по глубине*: одна и та же схема применяется во всех слоях и, как правило, требует обучения модели с нуля или дообучения. При этом многие из них по своей природе *стохастичны*: случайные признаки, случайные хеш-функции, случайные рёбра графа внимания. Из-за этого ошибка аппроксимации зависит от выборки, а результат вычислений воспроизводим лишь с точностью до зерна генератора.

Параллельно развивается механистическая интерпретируемость: она показывает, что слои трансформера неоднородны по своей функции [8, 25]. Математический анализ трансформерных схем [1] показывает, что модель без слоёв внимания приближает статистику биграмм. Однослойная модель, состоящая только из внимания, дополнительно реализует «skip-trigram»-зависимости. Индукционные головы, которые обеспечивают обучение в контексте, возникают лишь при композиции как минимум двух слоёв внимания [23]. Слои прямого распространения работают как память «ключ–значение», причём ключи нижних слоёв реагируют на поверхностные шаблоны (конкретные n-граммы), а верхних — на семантические [3]. Словарное обучение на активациях MLP небольшой модели выделяет интерпретируемые моносемантические признаки [24]. Известно также, что многоголовое самовнимание способно выражать свёрточные слои [4]. Значит, локальные позиционные паттерны внимания в принципе описываются фиксированными ядрами. Наконец, теоретический анализ показывает, что чистое внимание без остаточных связей и MLP вырождается по рангу дважды экспоненциально с глубиной [5]. Поэтому остаточный поток играет ключевую роль при любой послойной замене вычислений. Отдельно идёт дискуссия о том, являются ли обученные нейросети «уже чистыми» (*already clean*), то есть поддающимися явному описанию [6, 7, 9, 10]. [TODO: уточнить позиции авторов после прочтения эссе]

Эти наблюдения подсказывают иную постановку задачи. Если первые слои LLM реализуют в основном локальные, «поверхностные» вычисления, то их можно заменить *явными детерминированными алгоритмами* вместо единообразной аппроксимации внимания во всей сети. Под детерминированным алгоритмом мы понимаем процедуру, которая

1. не использует случайную выборку на этапе вывода;

2. строится по весам обученной модели и/или статистике корпуса в замкнутом виде или явной процедурой, без градиентного дообучения;

3. даёт одинаковый выход на одинаковом входе и допускает аналитическую оценку ошибки.

Примеры таких алгоритмов: таблицы поиска по окну из m последних токенов, фиксированные свёрточные или разреженные ядра вместо позиционных голов внимания, SVD и другие аналитические низкоранговые разложения матриц W_{QK} и W_{OV} [22], приближение Нистрёма с детерминированным выбором опорных точек [13].

Постановка задачи. Пусть $f = f_L \circ \cdots \circ f_1 \circ E$ — языковая модель из L блоков с матрицей эмбеддингов E, а $h_k(x)$ — состояние остаточного потока после k-го блока на входе x. Требуется построить детерминированный алгоритм A_k, такой что

$$\tilde{f} = f_L \circ \cdots \circ f_{k+1} \circ A_k, \qquad \mathbb{E}_x \, \mathrm{KL}\big(p_f(\cdot \mid x) \,\|\, p_{\tilde{f}}(\cdot \mid x)\big) \le \varepsilon,$$

и определить максимальную глубину $k^*(\varepsilon)$, для которой это возможно при ограничениях на вычислительную сложность и память алгоритма A_k.

Вклад работы. [TODO: сформулировать после экспериментов; черновой список:]

1. Формализация задачи детерминированной аппроксимации первых k слоёв LLM и метрик качества замены (KL-дивергенция выходных распределений, perplexity, близость состояний остаточного потока).
2. [TODO: Семейство алгоритмов]: таблицы поиска по ограниченному контексту, фиксированные ядра для позиционных голов, аналитические низкоранговые разложения.
3. Эмпирическая оценка критической глубины k^* на моделях [TODO: список моделей] и её связь с появлением индукционных голов [23].
4. Сравнение детерминированных и рандомизированных аппроксимаций [14, 15] при одинаковом бюджете вычислений.

Структура статьи. [TODO: В разделе 2 ..., в разделе 3 ...]

Список литературы

[1] N. Elhage et al. A Mathematical Framework for Transformer Circuits. Transformer Circuits Thread, 2021. `https://transformer-circuits.pub/2021/framework/index.html`

[2] A. Vaswani et al. Attention Is All You Need. NeurIPS, 2017. arXiv:1706.03762.

[3] M. Geva et al. Transformer Feed-Forward Layers Are Key-Value Memories. EMNLP, 2021. arXiv:2012.14913.

[4] J.-B. Cordonnier et al. On the Relationship between Self-Attention and Convolutional Layers. ICLR, 2020. arXiv:1911.03584.

[5] Y. Dong et al. Attention is Not All You Need: Pure Attention Loses Rank Doubly Exponentially with Depth. ICML, 2021. arXiv:2103.03404.

[6] N. Cammarata. Neural Networks Are Already Clean. Goodfire, 2026. `https://already-clean.goodfire.com/`

[7] L. Gao. Neural networks are not already clean. LessWrong, 2026. `https://www.lesswrong.com/posts/Dkh7pXKjoNWkkxQDz/neural-networks-are-not-already-clean`

[8] C. Olah et al. Zoom In: An Introduction to Circuits. Distill, 2020. https://distill.pub/2020/circuits/zoom-in/

[9] M. Lissack. Already Clean, Not Yet Meaningful: One "how" for the question Cammarata has opened. PhilArchive. https://philarchive.org/rec/LISACN

[10] S. Brodsky. Is AI easier to understand than scientists thought? IBM Think, 2026. https://www.ibm.com/think/news/is-ai-easier-to-understand-than-scientists-thought-goodfire-essay

[11] A. Katharopoulos et al. Transformers are RNNs: Fast Autoregressive Transformers with Linear Attention. ICML, 2020. arXiv:2006.16236.

[12] S. Wang et al. Linformer: Self-Attention with Linear Complexity, 2020. arXiv:2006.04768.

[13] Y. Xiong et al. Nyströmformer: A Nyström-Based Algorithm for Approximating Self-Attention. AAAI, 2021. arXiv:2102.03902.

[14] K. Choromanski et al. Rethinking Attention with Performers. ICLR, 2021. arXiv:2009.14794.

[15] H. Peng et al. Random Feature Attention. ICLR, 2021. arXiv:2103.02143.

[16] J. Lu et al. SOFT: Softmax-free Transformer with Linear Complexity. NeurIPS, 2021. arXiv:2110.11945.

[17] R. Child et al. Generating Long Sequences with Sparse Transformers, 2019. arXiv:1904.10509.

[18] N. Kitaev et al. Reformer: The Efficient Transformer. ICLR, 2020. arXiv:2001.04451.

[19] M. Zaheer et al. Big Bird: Transformers for Longer Sequences. NeurIPS, 2020. arXiv:2007.14062.

[20] J. Lee-Thorp et al. FNet: Mixing Tokens with Fourier Transforms. NAACL, 2022. arXiv:2105.03824.

[21] Y. Tay et al. Synthesizer: Rethinking Self-Attention in Transformer Models. ICML, 2021. arXiv:2005.00743.

[22] J. T. H. Wong et al. A3: an Analytical Low-Rank Approximation Framework for Attention, 2025. arXiv:2505.12942.

[23] C. Olsson et al. In-context Learning and Induction Heads. Transformer Circuits Thread, 2022. arXiv:2209.11895.

[24] T. Bricken et al. Towards Monosemanticity: Decomposing Language Models With Dictionary Learning. Transformer Circuits Thread, 2023. https://transformer-circuits.pub/2023/monosemantic-features/index.html

[25] D. Rai et al. A Practical Review of Mechanistic Interpretability for Transformer-Based Language Models, 2024. arXiv:2407.02646.

[26] Z. Yuan et al. ASVD: Activation-aware Singular Value Decomposition for Compressing Large Language Models, 2023. arXiv:2312.05821.

[27] X. Wang et al. SVD-LLM: Truncation-aware Singular Value Decomposition for Large Language Model Compression. ICLR, 2025. arXiv:2403.07378.

[28] Z. Liu et al. Deja Vu: Contextual Sparsity for Efficient LLMs at Inference Time. ICML, 2023. arXiv:2310.17157.

[29] Z. Zhang et al. MoEfication: Transformer Feed-forward Layers are Mixtures of Experts. Findings of ACL, 2022. arXiv:2110.01786.