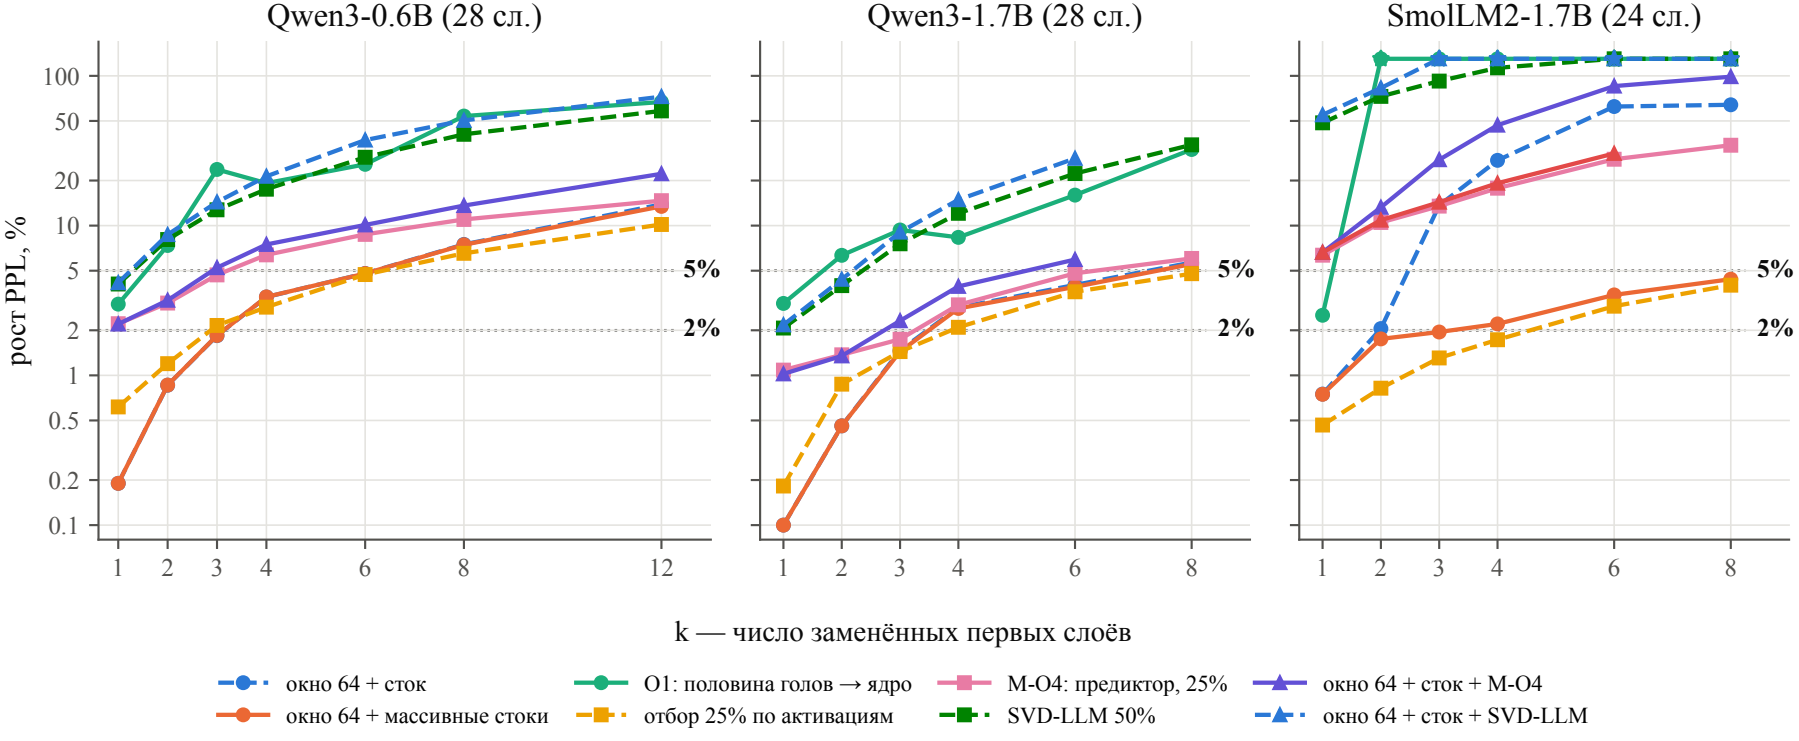

Qwen3-0.6B (28 сл.)
Qwen3-1.7B (28 сл.)
SmolLM2-1.7B (24 сл.)
рост PPL, %
100
50
20
10
5
2
1
0.5
0.2
0.1
5%
2%
1
2
3
4
6
8
12
k — число заменённых первых слоёв
окно 64 + сток
окно 64 + массивные стоки
O1: половина голов → ядро
отбор 25% по активациям
M-O4: предиктор, 25%
SVD-LLM 50%
окно 64 + сток + M-O4
окно 64 + сток + SVD-LLM