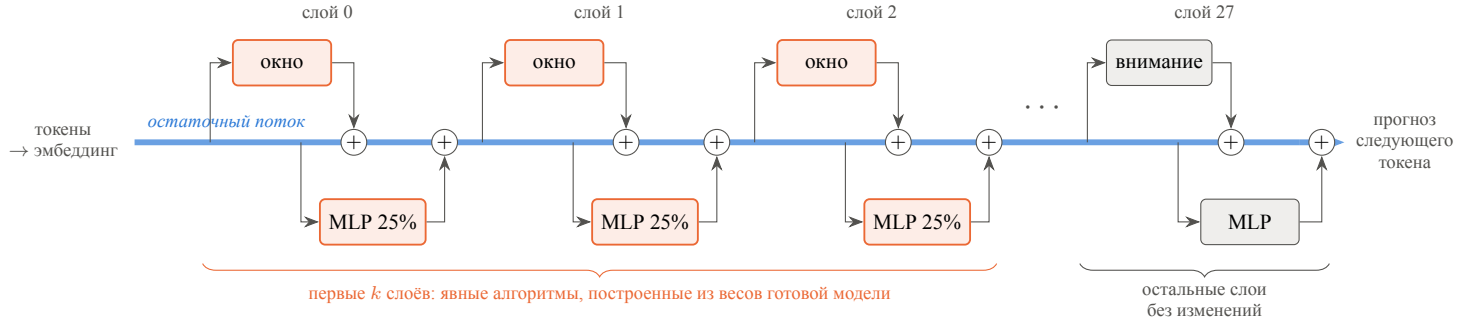
слой 0
слой 1
слой 2
слой 27
окно
окно
окно
внимание
токены
→ эмбеддинг
остаточный поток
MLP 25%
MLP 25%
MLP 25%
MLP
прогноз
следующего
токена
первые k слоёв: явные алгоритмы, построенные из весов готовой модели
остальные слои
без изменений