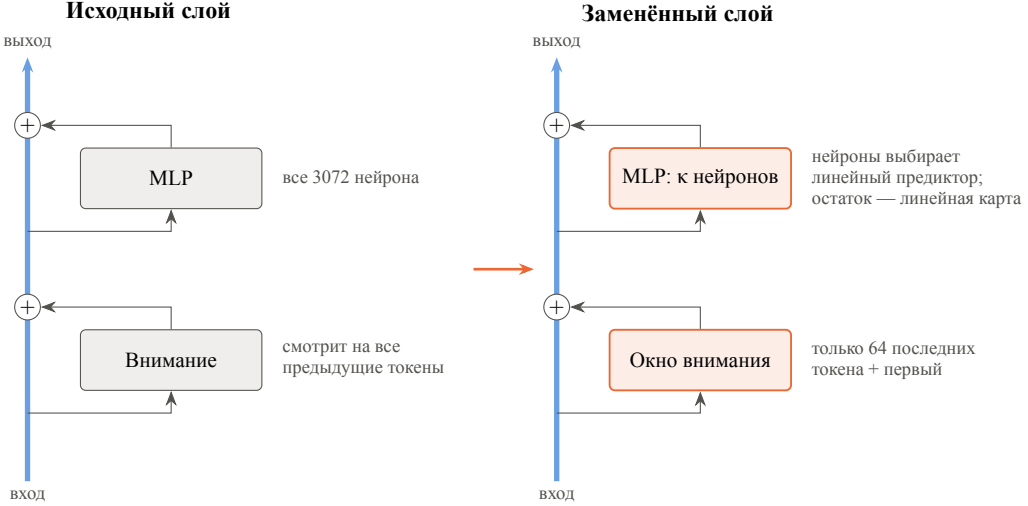
Исходный слой
выход
MLP
все 3072 нейрона
Внимание
смотрит на все
предыдущие токены
вход
Заменённый слой
выход
MLP: к нейронов
нейроны выбирает
линейный предиктор;
остаток — линейная карта
Окно внимания
только 64 последних
токена + первый
вход