Внимание: исходное

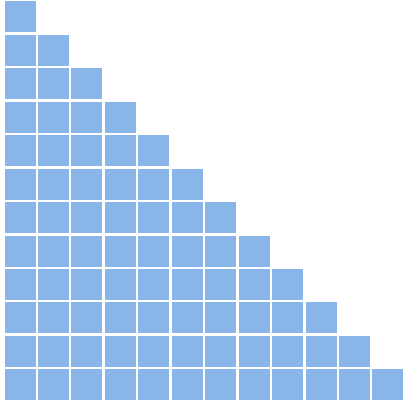

каждый токен (строка) смотрит
на все предыдущие (столбцы)

Замена: окно + сток

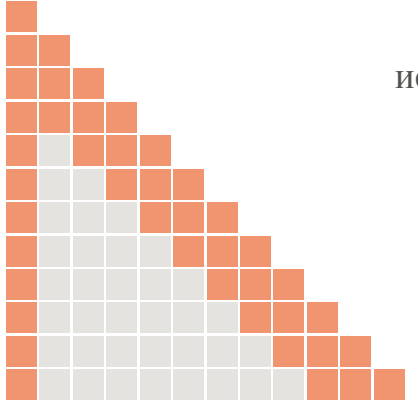

только ближайшие токены
и первый (сток)

MLP: какие нейроны считать

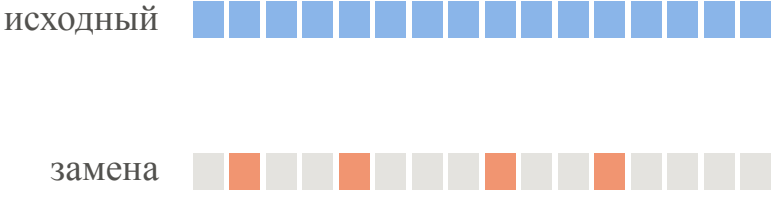

для каждого токена предиктор выбирает
25% нейронов; остаток — линейная поправка