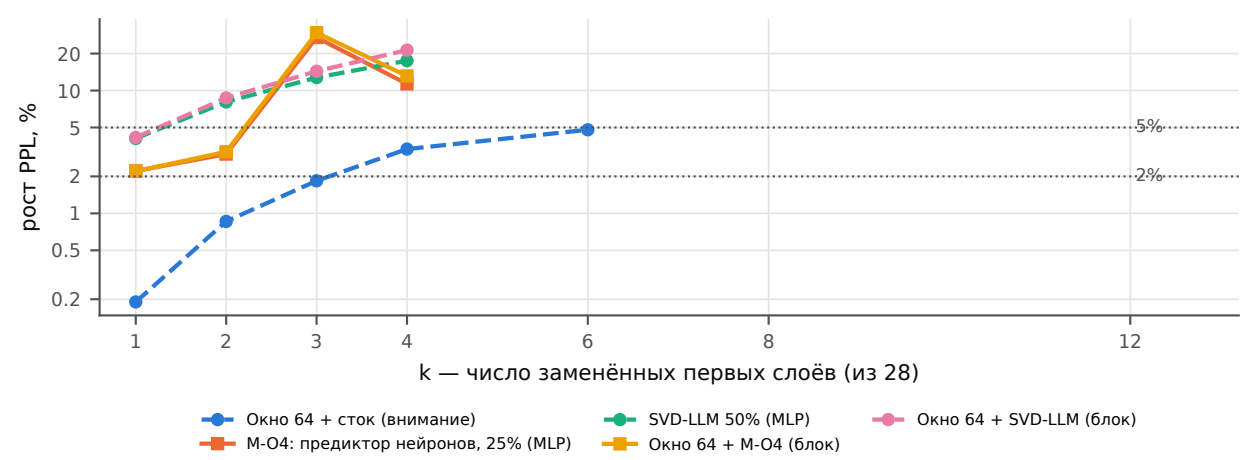
рост PPL, %
20
10
5
2
1
0.5
0.2
5%
2%
1
2
3
4
6
8
12
k — число заменённых первых слоёв (из 28)
Окно 64 + сток (внимание)
SVD-LLM 50% (MLP)
Окно 64 + SVD-LLM (блок)
M-O4: предиктор нейронов, 25% (MLP)
Окно 64 + M-O4 (блок)