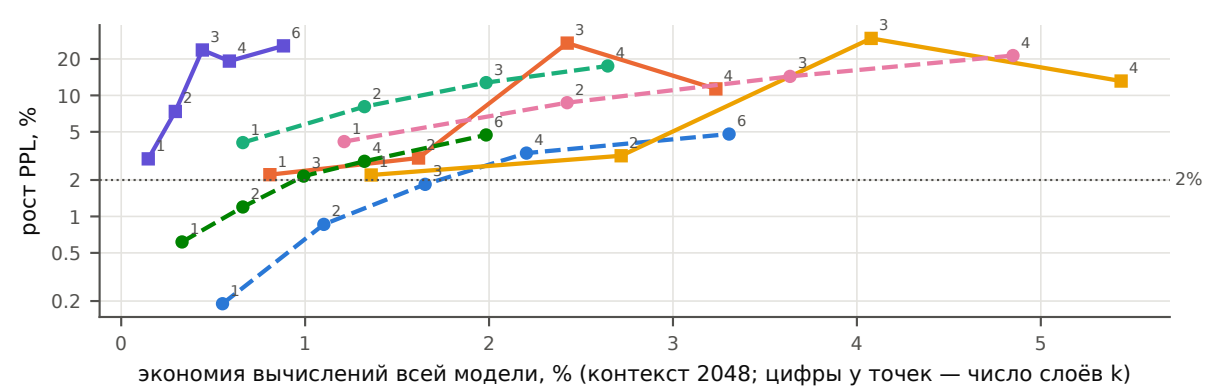
рост PPL, %
20
10
5
2
1
0.5
0.2
2%
0
1
2
3
4
5
экономия вычислений всей модели, % (контекст 2048; цифры у точек — число слоёв k)
Окно 64 + сток (внимание)
M-O4: предиктор нейронов, 25% (MLP)
SVD-LLM 50% (MLP)
Окно 64 + M-O4 (блок)
Окно 64 + SVD-LLM (блок)
Deja Vu-оракул 25% (MLP)
O1: половина голов — ядро (внимание)