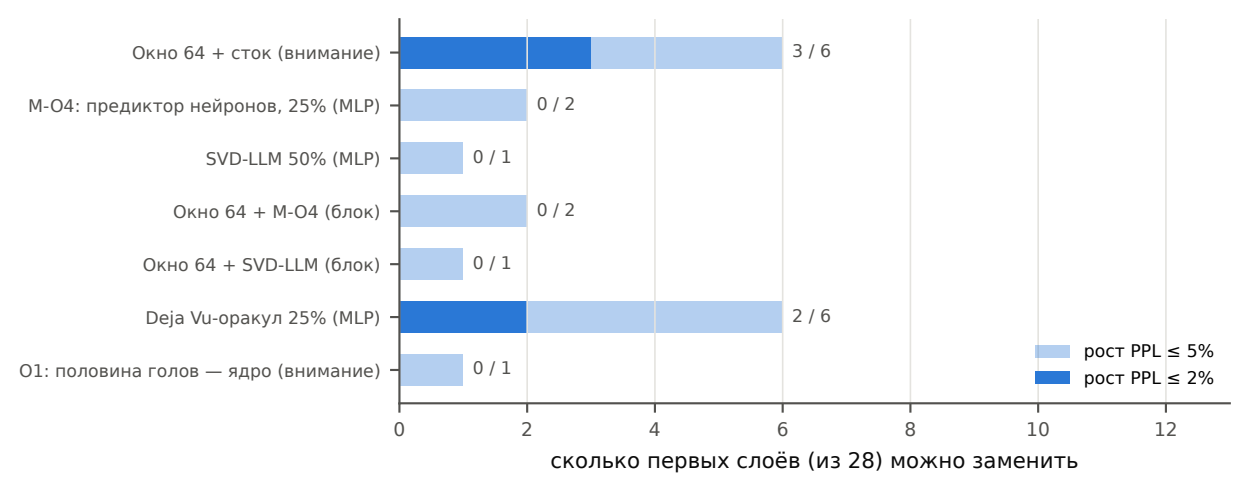
Окно 64 + сток (внимание)
M-O4: предиктор нейронов, 25% (MLP)
SVD-LLM 50% (MLP)
Окно 64 + M-O4 (блок)
Окно 64 + SVD-LLM (блок)
Deja Vu-оракул 25% (MLP)
O1: половина голов — ядро (внимание)
3 / 6
0 / 2
0 / 1
0 / 2
0 / 1
2 / 6
0 / 1
рост PPL ≤ 5%
рост PPL ≤ 2%
0
2
4
6
8
10
12
сколько первых слоёв (из 28) можно заменить