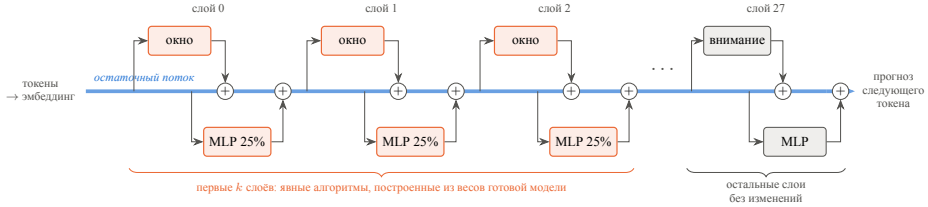
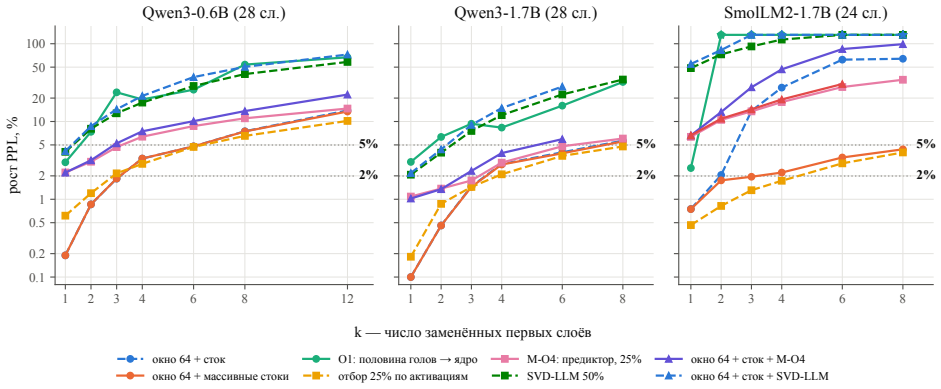
Детерминированная замена первых слоёв LLM: что можно, что нельзя и почему

Qwen3-0.6B, Qwen3-1.7B и SmolLM2-1.7B. Замены первых k слоёв строятся по явным формулам из весов и 128 тыс. токенов калибровки, без обучения и случайности. Калибровка: обучающая часть WikiText-103 (прямой прогон, без обучения); оценка: тест WikiText-2 и 7 бенчмарков.





Рост perplexity на WikiText-2 от числа заменённых слоёв k (пунктир — пороги 2 и 5 %).

- **Внимание заменяется почти даром:** окно 64 + сток — 3 слоя при росте PPL $\leq$ 2 %, 6 слоёв при $\leq$ 5 %; бенчмарки без изменений, KV-кэш до 21.3% меньше.
- **MLP первых слоёв незаменим:** лучший предиктор 25 % нейронов стоит 4.7% (0.6B) и 1.7% (1.7B) при $k = 3$; поправки плотные и высокоранговые.
- **Второе семейство (SmolLM2-1.7B):** сток привязан к токену «the» (нейрон 4987 слоя 1), а не к позиции; защита нейронов стока: 123 $\rightarrow$ 11 %; окно с массивными ключами при $k = 8$: 64 $\rightarrow$ 4.4 % без потерь на бенчмарках. MLP первых слоёв здесь дороже: оракул 25 % нейронов $\leq$ 4 % до $k = 8$, предиктор — 6 % уже при $k = 1$.

Остаточный поток — вектор каждого токена, идущий сквозь все слои; каждый слой читает его и *прибавляет* свою поправку.
Сток внимания — токен, на который остальные сбрасывают лишний вес внимания, когда «смотреть не на что»; без него вес размазывается по случайным токенам и модель ломается, поэтому замена обязана сохранять сток и нейроны, которые его создают.
Детерминированная замена — модуль, построенный по явной формуле из весов и калибровочного текста, без обучения и случайности.