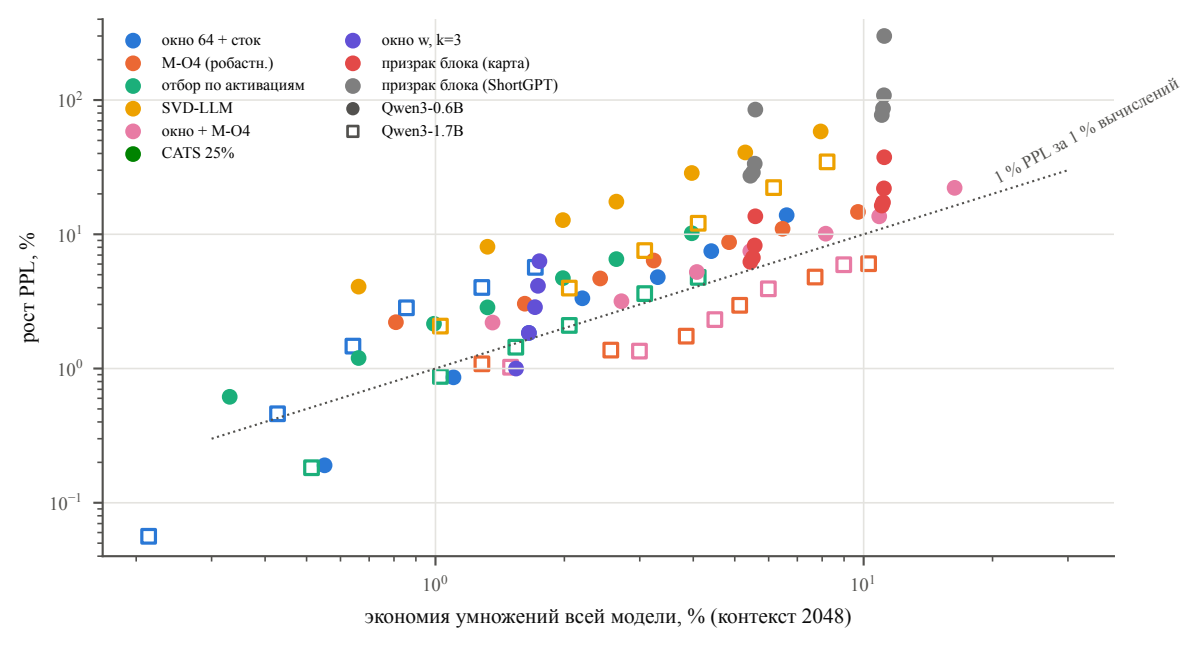
окно 64 + сток
M-O4 (робастн.)
отбор по активациям
SVD-LLM
окно + M-O4
CATS 25%
окно w, k=3
призрак блока (карта)
призрак блока (ShortGPT)
Qwen3-0.6B
Qwen3-1.7B
1 % PPL за 1 % вычислений
рост PPL, %
10^{2}
10^{1}
10^{0}
10^{-1}
10^{0}
10^{1}
экономия умножений всей модели, % (контекст 2048)