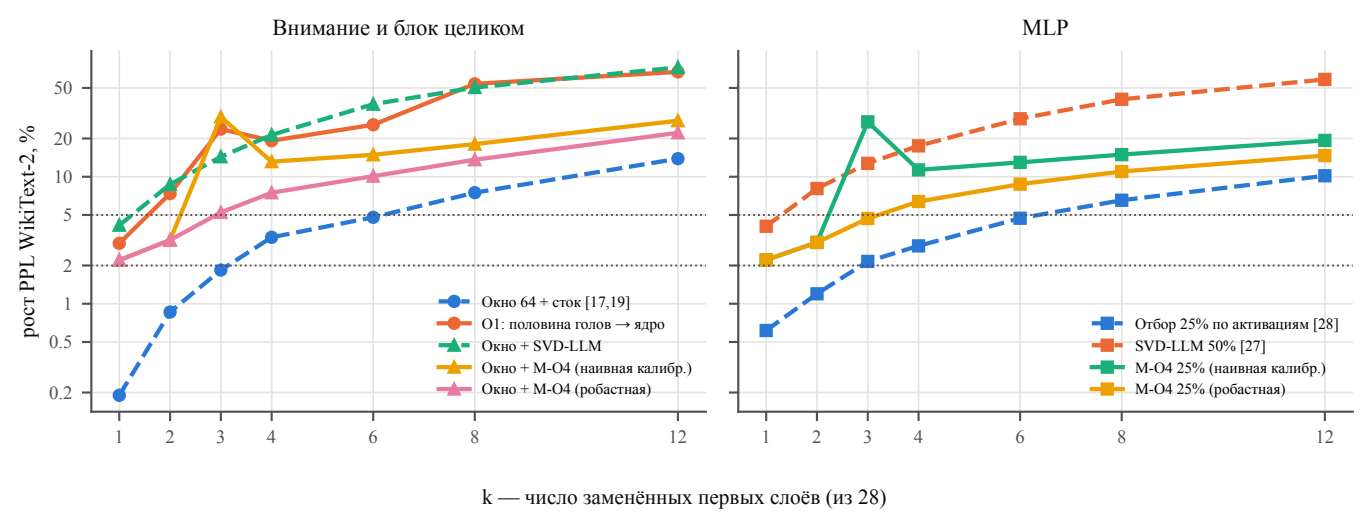
Внимание и блок целиком
MLP
рост PPL WikiText-2, %
50
20
10
5
2
1
0.5
0.2
1
2
3
4
6
8
12
Окно 64 + сток [17,19]
O1: половина голов → ядро
Окно + SVD-LLM
Окно + M-O4 (наивная калибр.)
Окно + M-O4 (робастная)
Отбор 25% по активациям [28]
SVD-LLM 50% [27]
M-O4 25% (наивная калибр.)
M-O4 25% (робастная)
k — число заменённых первых слоёв (из 28)