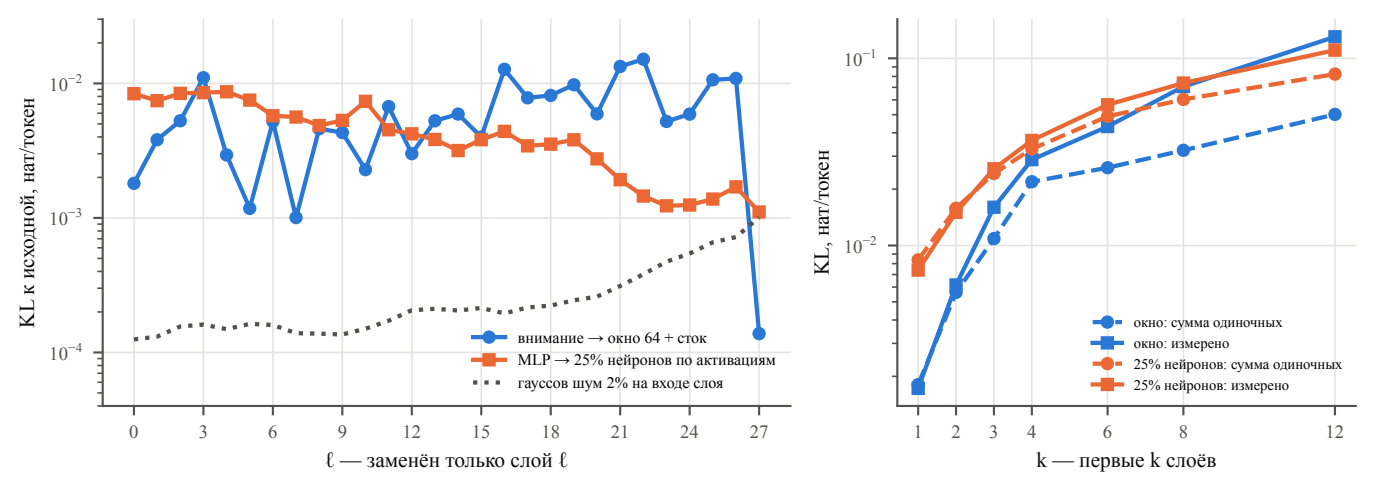
KL к исходной, нат/токен
10^{-2}
10^{-3}
10^{-4}
внимание → окно 64 + сток
MLP → 25% нейронов по активациям
гауссов шум 2% на входе слоя
0
3
6
9
12
15
18
21
24
27
ℓ — заменён только слой ℓ
KL, нат/токен
10^{-1}
10^{-2}
окно: сумма одиночных
окно: измерено
25% нейронов: сумма одиночных
25% нейронов: измерено
1
2
3
4
6
8
12
k — первые k слоёв