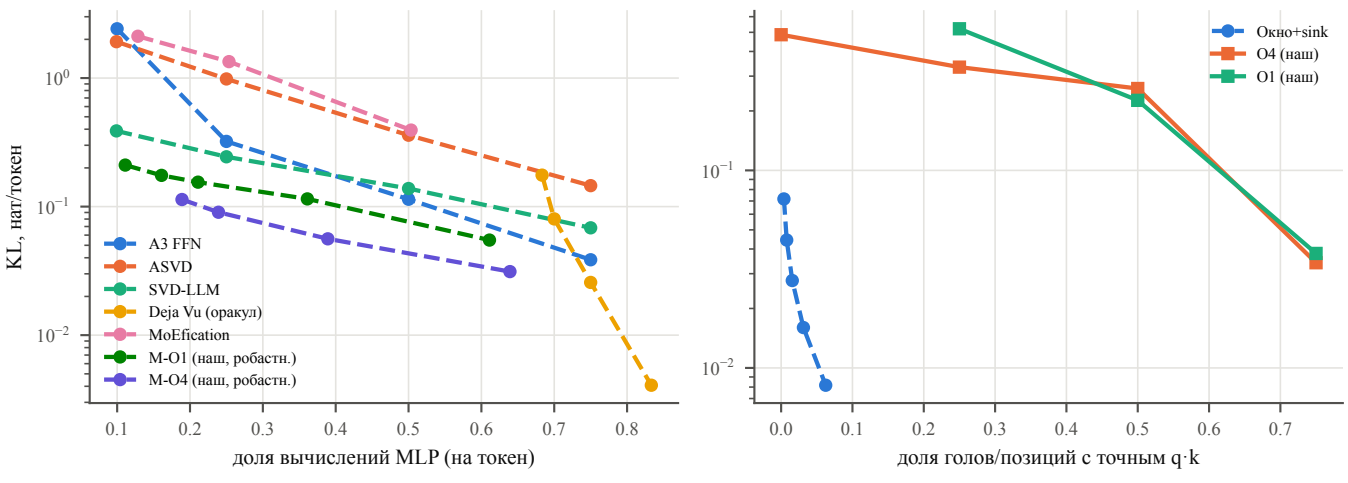
MLP, k=3
KL, нат/токен
10^{0}
10^{-1}
10^{-2}
A3 FFN
ASVD
SVD-LLM
Deja Vu (оракул)
MoEfication
M-O1 (наш, робастн.)
M-O4 (наш, робастн.)
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
доля вычислений MLP (на токен)
Внимание, k=3
Окно+sink
O4 (наш)
O1 (наш)
10^{-1}
10^{-2}
0.0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
доля голов/позиций с точным q·k