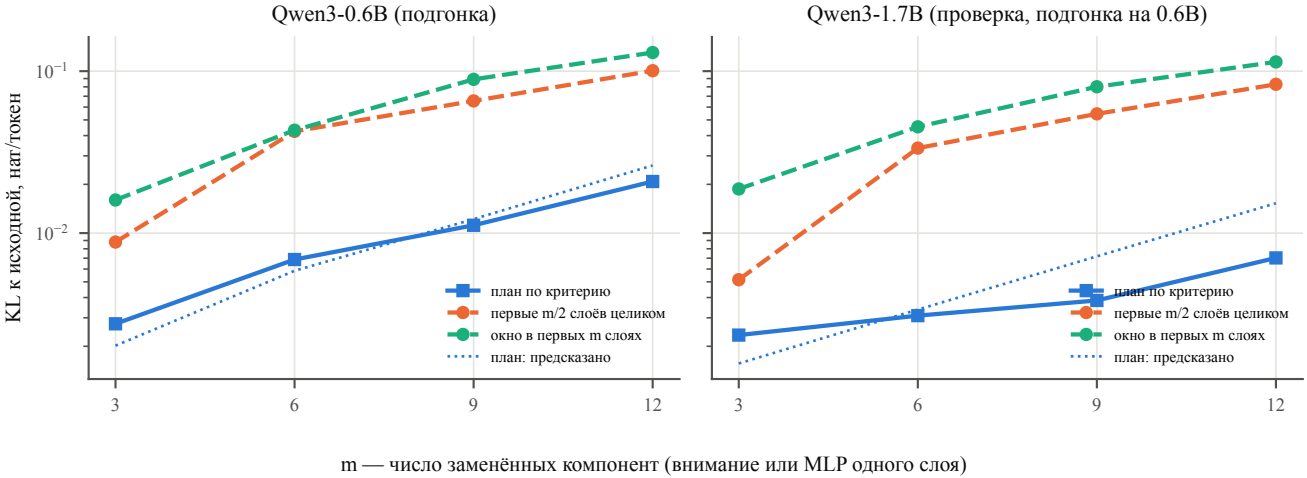
Qwen3-0.6B (подгонка)
Qwen3-1.7B (проверка, подгонка на 0.6B)
KL к исходной, нат/токен
10^{-1}
10^{-2}
3
6
9
12
план по критерию
первые m/2 слоёв целиком
окно в первых m слоях
план: предсказано
m — число заменённых компонент (внимание или MLP одного слоя)