Обзор литературы

к статье «Детерминированные алгоритмы аппроксимации первых слоёв LLM»

Обзор охватывает пять направлений: (1) архитектуру Transformer и её теоретические свойства; (2) механистическую интерпретируемость, которая объясняет, *что* вычисляют отдельные слои; (3) недавнюю дискуссию о том, являются ли нейросети «уже чистыми»; (4) методы эффективной аппроксимации самовнимания; (5) сжатие и разреженность слоёв MLP. В конце сформулированы выводы для нашей работы.

1 Архитектура Transformer и её свойства

Архитектура Transformer [2] отказалась от рекуррентности и свёрток в пользу многоголового масштабированного скалярного внимания $\mathrm{softmax}(QK^\top/\sqrt{d})V$, дополненного позиционным кодированием, остаточными связями и поэлементными слоями прямого распространения (MLP). Именно квадратичная по длине последовательности стоимость внимания мотивирует методы из раздела 4.

Два теоретических результата важны для понимания того, как устроены слои. Dong и др. [5] раскладывают выход сети из одних слоёв внимания на сумму путей и доказывают, что без остаточных связей и MLP такая сеть дважды экспоненциально по глубине сходится к матрице ранга 1. Остаточные связи этому препятствуют, а MLP замедляет вырождение. Отсюда следует, что остаточный поток — ключевой элемент любой послойной декомпозиции. Cordonnier и др. [4] показывают, что многоголовое самовнимание с относительным позиционным кодированием способно точно выразить любой свёрточный слой (ядро $\sqrt{N_h} \times \sqrt{N_h}$ при N_h головах). Эксперименты на изображениях подтверждают, что обученные головы действительно выучивают сеточные, свёрточные паттерны вокруг текущей позиции.

Значение для нашей работы: позиционные головы внимания можно описывать фиксированными ядрами [4], а заменять следует блок целиком, сохраняя остаточный поток [5].

2 Механистическая интерпретируемость

Программная работа «Zoom In» [8] формулирует три гипотезы: признаки (features) — базовые единицы нейросетей; признаки, связанные весами, образуют схемы (circuits); схожие признаки и схемы возникают в разных моделях (универсальность). На примере InceptionV1 разобраны детекторы кривых и другие схемы. Там же введено понятие полисемантических нейронов и приведён пример, который позже трактовался как суперпозиция.

Elhage и др. [1] переносят этот подход на трансформеры. Остаточный поток рассматривается как линейный канал связи, головы внимания — как независимые аддитивные компоненты с QK-схемой (куда смотреть) и OV-схемой (что переносить). Для моделей только из внимания получены точные описания: модель без слоёв реализует статистику биграмм, однослойная — биграммы и «skip-триграммы», а двухслойная за счёт композиции голов строит индукционные головы. Olsson и др. [23] показывают, что индукционные головы (паттерн $[A][B]\dots[A] \to [B]$) появляются в ходе обучения скачкообразно, в «фазовом переходе», совпадающем с резким улучшением обучения в контексте. Для малых моделей связь доказана причинно, для больших приведены корреляционные свидетельства.

Geva и др. [3] интерпретируют слой MLP как память «ключ–значение»: ключи (строки первой матрицы) срабатывают на текстовые шаблоны, а значения задают распределения над словарём следующего токена. Принципиально для нас, что ключи *нижних* слоёв реагируют на поверхностные шаблоны (например, конкретные n-граммы), а верхних — на семантические.

Bricken и др. [24] обучают разреженный автокодировщик (словарное обучение) на активациях MLP однослойного трансформера. Получаются тысячи признаков, значительно более моносемантичных, чем исходные нейроны (например, признаки ДНК, арабского письма, base64), а с ростом словаря признаки «расщепляются» на более узкие. Rai и др. [25] дают практический обзор области: таксономию задач (изучение признаков, схем, универсальности), методов (probing, патчинг активаций, словарное обучение и др.) и открытых проблем.

Значение для нашей работы: есть точные описания вычислений для моделей глубины 0–1 [1], свидетельства «поверхностности» ранних MLP [3] и естественная граница сложности — композиция слоёв, порождающая индукционные головы [23].

3 Дискуссия «Neural networks are already clean»

В эссе Cammarata [6] (Goodfire, 2026; автор называет его «рабочей гипотезой») утверждается, что каноническое свидетельство полисемантичности и суперпозиции было неверно истолковано. Неинтерпретируемость поздних слоёв InceptionV1 объясняется не суперпозицией, а архитектурными проблемами и слабыми инструментами. После обычных улучшений обучения 99–100% нейронов последнего слоя становятся интерпретируемыми. Полисемантичность в основном объясняется мотивом «рекурсивного обобщения», то есть объединением *связанных* понятий. По предварительной оценке для Qwen3-32B около 90% «полюсов» нейронов имеют одну основную функцию, около 7% — две связанные, и лишь 2–4% пока не объяснены. Вывод автора: сеть можно изучать напрямую, без промежуточной декомпозиции вроде разреженных автокодировщиков [24].

Gao [7] принимает главное наблюдение (полисемантичность переоценивали), но возражает, что совпадение активирующих примеров с шаблоном недостаточно для объяснения нейрона. Во-первых, из того, что все активирующие примеры подходят под шаблон, не следует, что каждый подходящий пример активирует нейрон. Во-вторых, важна величина активаций: по его данным, обнуление слабых активаций заметно ухудшает модель. Gao предлагает критерий: объяснение верно, если подстановка *смоделированных* по нему активаций вместо настоящих не увеличивает KL-дивергенцию выходного распределения модели на большом корпусе. Кроме того, понимание отдельных нейронов не даёт понимания вычислений *между* ними:

найденные схемы остаются большими и избыточными.

Обзорная заметка IBM Think [10] пересказывает эссе и собирает мнения исследователей: разметка нейронов не равна пониманию модели; пики активаций покрывают малую долю срабатываний; словарное обучение остаётся полезным для слабых активаций; нужны интервенционные эксперименты. Работа Lissack [9], судя по названию («Already Clean, Not Yet Meaningful»), разводит «чистоту» внутренних механизмов и их содержательную осмысленность. [TODO: прочитать текст: PhilArchive не отдаёт страницу автоматически]

Значение для нашей работы: задача замены первых слоёв явным алгоритмом — это конструктивная проверка тезиса о «чистоте» на уровне целых слоёв. Критерий Gao (downstream KL при подстановке) совпадает с нашей основной метрикой качества аппроксимации, а его замечание о слабых активациях указывает на главный риск табличных аппроксимаций.

4 Эффективные аппроксимации внимания

4.1 Ядерные и линейные методы

Katharopoulos и др. [11] заменяют $\exp(q^\top k)$ на скалярное произведение признаковых отображений $\phi(q)^\top \phi(k)$ с $\phi(x) = \mathrm{elu}(x) + 1$. Ассоциативность матричного произведения даёт сложность $O(n)$, а авторегрессионная модель становится рекуррентной сетью с постоянной памятью на шаг. Performer [14] (механизм FAVOR+) строит *несмещённую* оценку softmax-ядра положительными ортогональными случайными признаками и доказывает оценки её точности. RFA [15] аппроксимирует softmax-ядро случайными фурье-признаками и добавляет механизм гейтинга для смещения внимания к недавним токенам. SOFT [16] отказывается от softmax в пользу гауссова ядра, что позволяет построить детерминированное низкоранговое разложение с опорными точками. Псевдообратная матрица при этом вычисляется итерациями Ньютона–Рафсона.

4.2 Низкоранговые методы

Linformer [12] опирается на наблюдение, что матрица внимания имеет низкий эффективный ранг, и проецирует K и V по оси последовательности обучаемыми матрицами в размерность $k \ll n$. Nyströmformer [13] аппроксимирует softmax-матрицу методом Нистрёма с опорными точками, выбранными как средние по сегментам последовательности, то есть детерминированно. A3 [22] — метод сжатия *после обучения*: слой разбивается на функциональные компоненты QK, OV и MLP, и для каждого аналитически находится уменьшение скрытой размерности, минимизирующее функциональную ошибку компонента. В отличие от разложения весовой матрицы на два сомножителя, это не добавляет накладных расходов при выводе. На LLaMA 3.1-70B метод заметно превосходит предыдущие низкоранговые подходы по perplexity при равном бюджете.

4.3 Разреженные шаблоны внимания

Sparse Transformer [17] использует фиксированные факторизованные (strided и fixed) шаблоны со сложностью $O(n\sqrt{n})$ и моделирует последовательности дли-

ной в десятки тысяч элементов. Reformer [18] группирует близкие запросы и ключи локально-чувствительным хешированием (случайные повороты), получая $O(n \log n)$, и экономит память обратимыми остаточными слоями. BigBird [19] комбинирует локальное окно, глобальные токены и случайные рёбра и доказывает, что такое разреженное внимание сохраняет универсальность аппроксимации и полноту по Тьюрингу.

4.4 Замена внимания

FNet [20] заменяет подслой самовнимания непараметрическим двумерным дискретным преобразованием Фурье и достигает 92–97% точности BERT на GLUE при существенно более быстром обучении. Synthesizer [21] показывает, что веса внимания можно синтезировать без попарного взаимодействия токенов: по каждому токену в отдельности (Dense) или вообще независимо от входа (Random). Такие модели остаются конкурентоспособными на ряде задач.

4.5 Сводка

Метод	Способ аппроксимации	Случайность	Нужно обучение
Linear Attention [11]	ядро $\mathrm{elu} + 1$	нет	да
Performer [14]	случайные ортогональные признаки	да	да
RFA [15]	случайные фурье-признаки	да	да
SOFT [16]	гауссово ядро + низкий ранг	нет	да
Linformer [12]	обучаемые проекции по длине	нет	да
Nyströmformer [13]	метод Нистрёма, сегментные средние	нет	да
A3 [22]	аналитическое снижение ранга QK/OV/MLP	нет	**нет**
Sparse Transformer [17]	фиксированные разреженные шаблоны	нет	да
Reformer [18]	LSH-хеширование	да	да
BigBird [19]	окно + глобальные + случайные рёбра	да	да
FNet [20]	преобразование Фурье	нет	да
Synthesizer [21]	синтезированные веса внимания	нет	да

Таблица 1: Методы эффективного внимания. «Нужно обучение»: метод предполагает обучение модели с нуля или дообучение, а не построение по весам готовой модели.

5 Сжатие и разреженность слоёв MLP

Слой MLP в современных LLM (в Qwen3 — SwiGLU, $\mathrm{down}(\mathrm{silu}(W_g x) \odot W_u x)$) содержит большую часть параметров блока. Для его ускорения после обучения есть два подхода.

Низкоранговые разложения с учётом активаций. Простое SVD весовой матрицы плохо работает для LLM из-за выбросов в активациях. ASVD [26] масштабирует столбцы весовой матрицы по статистике активаций, так что выбросы «поглощаются» весами перед разложением, и подбирает ранг послойно с учётом чувствительности слоёв. Без обучения это сжимает сеть на 10–30%. SVD-LLM [27] предлагает «отбеливание» данных, согласованное с усечением: после него каждое отброшенное сингулярное число напрямую соответствует потере на калибровочных данных. Затем сжатые веса дообучаются последовательной низкоранговой аппроксимацией. Первая часть — замкнутая форма, вторая требует градиентного обучения. Эти методы применимы к любым линейным проекциям, включая проекции внимания. Отбор нейронов MLP в A3 [22] относится к той же группе: это детерминированный критерий в замкнутой форме.

Разреженность активаций. MoEfication [29] исходит из наблюдения, что на каждом входе активна малая доля нейронов FFN. Метод разбивает нейроны на группы-«эксперты» и строит маршрутизатор, выбирающий группы для входа. В итоге используется 10–30% параметров FFN при сохранении более 95% исходного качества. Deja Vu [28] обобщает идею до «контекстной разреженности»: для каждого входа существует малое подмножество голов внимания и нейронов MLP, дающее почти тот же выход. Это подмножество предсказывается лёгким обучаемым предиктором и используется для ускорения вывода больших моделей более чем в два раза. Обе работы опираются на интерпретацию MLP как памяти «ключ–значение» [3]: на конкретном входе срабатывают немногие ключи.

Значение для нашей работы: для MLP первых слоёв сравниваем детерминированные части этих методов: разложения ASVD и SVD-LLM без дообучения, разбиение MoEfication с маршрутизацией без обучения, «оракульную» контекстную разреженность как верхнюю границу для Deja Vu. Их обучаемые компоненты (дообучение SVD-LLM, предиктор Deja Vu) оцениваем только в отдельном треке с дистилляцией.

6 Выводы и место нашей работы

1. Методы эффективного внимания применяют *одну и ту же* аппроксимацию во всех слоях и, за исключением A3 [22], требуют обучения. Зависимость качества аппроксимации от глубины слоя в них не исследуется.

2. Значительная часть методов стохастична ([14, 15, 18, 19]). Детерминированные альтернативы ([13, 16, 17, 20]) существуют, но не сравнивались с ними именно как post-hoc замена слоёв обученной модели.

3. Интерпретируемость даёт основания считать первые слои простыми: биграммы и skip-триграммы [1], поверхностные шаблоны в MLP [3], свёрточные позиционные паттерны [4]. Однако эти наблюдения не превращены в работающий алгоритм, который заменял бы слои целиком.

4. Методы сжатия MLP [26, 27, 29, 28] оценивают качество на всей модели при равномерном сжатии слоёв. Вопрос, насколько полно MLP *первых* слоёв заменяется таблицами и линейными картами в замкнутой форме, остаётся открытым.

5. Дискуссия о «чистоте» нейросетей [6, 7] даёт и мотивацию, и критерий проверки: явная замена слоёв, оцениваемая по downstream KL, — строгая форма утверждения «мы понимаем, что делают эти слои».

Наша работа закрывает этот пробел: мы строим детерминированные алгоритмы, заменяющие первые k слоёв обученной LLM без дообучения, и определяем глубину k^*, до которой такая замена возможна.

Список литературы

[1] N. Elhage et al. A Mathematical Framework for Transformer Circuits. Transformer Circuits Thread, 2021. https://transformer-circuits.pub/2021/framework/index.html

[2] A. Vaswani et al. Attention Is All You Need. NeurIPS, 2017. arXiv:1706.03762.

[3] M. Geva et al. Transformer Feed-Forward Layers Are Key-Value Memories. EMNLP, 2021. arXiv:2012.14913.

[4] J.-B. Cordonnier et al. On the Relationship between Self-Attention and Convolutional Layers. ICLR, 2020. arXiv:1911.03584.

[5] Y. Dong et al. Attention is Not All You Need: Pure Attention Loses Rank Doubly Exponentially with Depth. ICML, 2021. arXiv:2103.03404.

[6] N. Cammarata. Neural Networks Are Already Clean. Goodfire, 2026. https://already-clean.goodfire.com/

[7] L. Gao. Neural networks are not already clean. LessWrong, 2026. https://www.lesswrong.com/posts/Dkh7pXKjoNWkkxQDz/neural-networks-are-not-already-clean

[8] C. Olah et al. Zoom In: An Introduction to Circuits. Distill, 2020. https://distill.pub/2020/circuits/zoom-in/

[9] M. Lissack. Already Clean, Not Yet Meaningful: One "how" for the question Cammarata has opened. PhilArchive. https://philarchive.org/rec/LISACN

[10] S. Brodsky. Is AI easier to understand than scientists thought? IBM Think, 2026. https://www.ibm.com/think/news/is-ai-easier-to-understand-than-scientists-thought-goodfire-essay

[11] A. Katharopoulos et al. Transformers are RNNs: Fast Autoregressive Transformers with Linear Attention. ICML, 2020. arXiv:2006.16236.

[12] S. Wang et al. Linformer: Self-Attention with Linear Complexity, 2020. arXiv:2006.04768.

[13] Y. Xiong et al. Nyströmformer: A Nyström-Based Algorithm for Approximating Self-Attention. AAAI, 2021. arXiv:2102.03902.

[14] K. Choromanski et al. Rethinking Attention with Performers. ICLR, 2021. arXiv:2009.14794.

[15] H. Peng et al. Random Feature Attention. ICLR, 2021. arXiv:2103.02143.

[16] J. Lu et al. SOFT: Softmax-free Transformer with Linear Complexity. NeurIPS, 2021. arXiv:2110.11945.

[17] R. Child et al. Generating Long Sequences with Sparse Transformers, 2019. arXiv:1904.10509.

[18] N. Kitaev et al. Reformer: The Efficient Transformer. ICLR, 2020. arXiv:2001.04451.

[19] M. Zaheer et al. Big Bird: Transformers for Longer Sequences. NeurIPS, 2020. arXiv:2007.14062.

[20] J. Lee-Thorp et al. FNet: Mixing Tokens with Fourier Transforms. NAACL, 2022. arXiv:2105.03824.

[21] Y. Tay et al. Synthesizer: Rethinking Self-Attention in Transformer Models. ICML, 2021. arXiv:2005.00743.

[22] J. T. H. Wong et al. A3: an Analytical Low-Rank Approximation Framework for Attention, 2025. arXiv:2505.12942.

[23] C. Olsson et al. In-context Learning and Induction Heads. Transformer Circuits Thread, 2022. arXiv:2209.11895.

[24] T. Bricken et al. Towards Monosemanticity: Decomposing Language Models With Dictionary Learning. Transformer Circuits Thread, 2023. `https://transformer-circuits.pub/2023/monosemantic-features/index.html`

[25] D. Rai et al. A Practical Review of Mechanistic Interpretability for Transformer-Based Language Models, 2024. arXiv:2407.02646.

[26] Z. Yuan et al. ASVD: Activation-aware Singular Value Decomposition for Compressing Large Language Models, 2023. arXiv:2312.05821.

[27] X. Wang et al. SVD-LLM: Truncation-aware Singular Value Decomposition for Large Language Model Compression. ICLR, 2025. arXiv:2403.07378.

[28] Z. Liu et al. Deja Vu: Contextual Sparsity for Efficient LLMs at Inference Time. ICML, 2023. arXiv:2310.17157.

[29] Z. Zhang et al. MoEfication: Transformer Feed-forward Layers are Mixtures of Experts. Findings of ACL, 2022. arXiv:2110.01786.