Детерминированные алгоритмы аппроксимации первых слоёв LLM

Чанкаев Шамиль, Мархабаев Бекет

Аннотация

Первые слои больших языковых моделей (LLM) на основе архитектуры Transformer [2] выполняют сравнительно простые операции: восстанавливают статистику биграмм и коротких n-грамм [1], реализуют фиксированные позиционные паттерны внимания и хранят поверхностные шаблоны в слоях прямого распространения [3]. Мы исследуем гипотезу о том, что вычисления первых k слоёв можно заменить *детерминированными* алгоритмами, то есть процедурами без случайной выборки и без дообучения градиентным спуском, которые строятся по весам модели и статистике калибровочного корпуса в замкнутой форме. Мы адаптируем к каузальному декодеру Qwen3 методы эффективного внимания и сжатия слоёв MLP из литературы и предлагаем собственные: факторизацию внимания «позиционное ядро $\times$ значимость ключевого токена», типизированную замену голов, линеаризацию MLP с компенсацией дрейфа остаточного потока и табличные замены блоков. Эксперименты проводятся на Qwen3-0.6B и 1.7B (Base) с оценкой по KL-дивергенции к исходной модели, perplexity и стандартным бенчмаркам. Профилирование показывает, что первые слои образуют отдельный режим «до стока внимания»: массивная активация первого токена и сток внимания возникают лишь после нескольких первых слоёв, что задаёт естественную глубину замены k_{sink}. Мы также показываем, что рандомизированные признаки FAVOR+ (Performer [14]) неприменимы к первым слоям без переобучения: нормы ключей после QK-нормализации лежат далеко за пределами области, где их оценка ядра устойчива. Основные результаты. (1) Внимание первых трёх слоёв заменяется окном из 64 позиций со стоком с ростом perplexity 1.5–1.8 % и без потерь на семи бенчмарках; MLP первых слоёв заменяется хуже: лучший метод — предложенный детерминированный предиктор активных нейронов — стоит 4.7 % (0.6B) и 1.7 % (1.7B) при четверти вычислений MLP, а по карте заменяемости MLP ранних слоёв оказываются самыми незаменимыми в модели. (2) Мы обнаруживаем ловушку калибровки в замкнутой форме: единичные токены с массивной активацией доминируют в задаче наименьших квадратов, ошибка ложится в каналы стока внимания и обрушивает модель; мы даём формулу влияния строки, воспроизводим эффект дозой отравленных окон и устраняем его исключением строк-выбросов, а также показываем, что массивную активацию создают один–пять нейронов, удаление которых разрушает модель. (3) Априорные статистики слоя предсказывают KL его замены с ранговой корреляцией 0.9–0.97 и позволяют планировать замены на непросмотренной модели в 10–15 раз точнее замены префикса. (4) На втором семействе (SmolLM2-1.7B, Llama-3.2-1B) сток оказывается привязан не к позиции, а к токену: один нейрон создаёт массивную активацию на «the» в любой позиции, и замены переносятся лишь с защитой таких нейронов и хранением таких ключей (окно: $64 \to 4$ % PPL при $k = 8$); MLP первых слоёв у этого семейства заменяется хуже, а планировщик переносится. Результаты дополняют дискуссию о том, насколько внутренние вычисления обученных сетей «уже чисты» и поддаются явному описанию [6, 7].

Ключевые слова: трансформеры, большие языковые модели, аппроксимация внимания, механистическая интерпретируемость, детерминированные алгоритмы, низкоранговые приближения, сжатие MLP.

1 Введение

Архитектура Transformer [2] стала основой современных больших языковых моделей. Её центральный механизм, самовнимание (self-attention), требует $O(n^2)$ операций по длине последовательности n. Это породило большое семейство методов эффективной аппроксимации внимания. Их можно условно разделить на несколько групп:

- **ядерные и линейные** методы, в которых softmax заменяется скалярным произведением признаковых отображений: линейное внимание [11], Performer со случайными признаками FAVOR+ [14], случайные фурье-признаки RFA [15], SOFT без softmax [16];
- **низкоранговые** методы: проекции Linformer по оси последовательности [12], приближение Нистрёма в Nyströmformer [13], аналитический фреймворк A3 [22];
- **разреженные** шаблоны внимания: Sparse Transformer [17], хеширование LSH в Reformer [18], комбинация локального, глобального и случайного внимания в BigBird [19];
- **замена внимания** фиксированным или синтезированным смешиванием токенов: преобразование Фурье в FNet [20], Synthesizer [21].

Почти все эти методы аппроксимируют механизм внимания *равномерно по глубине*: одна и та же схема применяется во всех слоях и, как правило, требует обучения модели с нуля или дообучения. При этом многие из них по своей природе *стохастичны*: случайные признаки, случайные хеш-функции, случайные рёбра графа внимания. Из-за этого ошибка аппроксимации зависит от выборки, а результат вычислений воспроизводим лишь с точностью до зерна генератора.

Параллельно развивается механистическая интерпретируемость: она показывает, что слои трансформера неоднородны по своей функции [8, 25]. Математический анализ трансформерных схем [1] показывает, что модель без слоёв внимания приближает статистику биграмм. Однослойная модель, состоящая только из внимания, дополнительно реализует «skip-trigram»-зависимости. Индукционные головы, которые обеспечивают обучение в контексте, возникают лишь при композиции как минимум двух слоёв внимания [23]. Слои прямого распространения работают как память «ключ–значение», причём ключи нижних слоёв реагируют на поверхностные шаблоны (конкретные n-граммы), а верхних — на семантические [3]. Словарное обучение на активациях MLP небольшой модели выделяет интерпретируемые моносемантические признаки [24]. Известно также, что многоголовое самовнимание способно выражать свёрточные слои [4]. Значит, локальные позиционные паттерны внимания в принципе описываются фиксированными ядрами. Наконец, теоретический анализ показывает, что чистое внимание без остаточных связей и MLP вырождается по рангу дважды экспоненциально с глубиной [5]. Поэтому остаточный поток играет ключевую роль при любой послойной замене вычислений. Отдельно идёт дискуссия о том, являются ли обученные нейросети «уже чистыми» (*already clean*), то есть поддающимися явному описанию [6, 7, 9, 10]. Cammarata [6] утверждает, что видимая полисемантичность нейронов в основном объясняется не суперпозицией, а «рекурсивным обобщением» связанных понятий, и по предварительной оценке около 90% «полюсов» нейронов Qwen3-32B (положительная или отрицательная сторона активации) имеют одну основную функцию. Gao [7] возражает, что совпадения активирующих примеров с шаблоном недостаточно, и предлагает строгий критерий: объяснение верно, если подстановка смоделированных по нему активаций не увеличивает KL-дивергенцию выходного распределения модели. Именно этот критерий — KL при подстановке — мы используем как основную метрику замены слоёв.

Эти наблюдения подсказывают иную постановку задачи. Если первые слои LLM реализуют в основном локальные, «поверхностные» вычисления, то их можно заменить *явными детерминированными алгоритмами* вместо единообразной аппроксимации внимания во всей сети. Под детерминированным алгоритмом мы понимаем процедуру, которая

1. не использует случайную выборку на этапе вывода;
2. строится по весам обученной модели и/или статистике корпуса в замкнутом виде или явной процедурой, без градиентного дообучения;
3. даёт одинаковый выход на одинаковом входе и допускает аналитическую оценку ошибки.

Примеры таких алгоритмов: фиксированные разреженные шаблоны внимания, позиционные ядра вместо голов внимания, таблицы поиска по токенам, аналитические низкоранговые разложения матриц W_{QK}, W_{OV} и весов MLP [22, 26, 27], линейные карты, подогнанные гребневой регрессией.

Постановка задачи. Пусть $f = f_L \circ \cdots \circ f_1 \circ E$ — языковая модель из L блоков с матрицей эмбеддингов E, а $h_k(x)$ — состояние остаточного потока после k-го блока на входе x. Требуется построить детерминированный алгоритм A_k, такой что

$$\tilde{f} = f_L \circ \cdots \circ f_{k+1} \circ A_k, \qquad \mathbb{E}_x \, \mathrm{KL}\big(p_f(\cdot \mid x) \,\|\, p_{\tilde{f}}(\cdot \mid x)\big) \le \varepsilon,$$

и определить максимальную глубину $k^*(\varepsilon)$, для которой это возможно при ограничениях на вычислительную сложность и память алгоритма A_k.

Вклад работы.

1. Формализация задачи детерминированной аппроксимации первых k слоёв LLM с критерием качества «KL при подстановке» и протокол, в котором исходная и изменённая модели сравниваются в одном процессе в fp32 (шум bf16 сам по себе даёт KL$\approx 10^{-3}$).

2. Адаптация к каузальному декодеру с GQA, QK-нормализацией и RoPE шести методов эффективного внимания и пяти методов сжатия MLP из литературы; разбор того, почему Linformer, Nyströmformer, FNet, SOFT и Reformer неприменимы без переобучения.

3. Новые детерминированные методы: факторизация внимания «позиционное ядро $\times$ значимость ключевого токена» (O4), типизированная замена голов (O1), ридж-свёртка вместо внимания (O2), аддитивная n-граммная замена блоков (O3), линеаризация MLP с точными нейронами (M-O1), табличный (M-O2) и кусочно-линейный (M-O3) MLP. Все наши методы калибруются последовательно с компенсацией накопленного дрейфа.

4. Послойный профиль Qwen3-0.6B и 1.7B, выделяющий режим «до стока внимания» и задающий глубину k_{sink}, и анализ неприменимости случайных признаков к первым слоям.

5. Сравнение по KL, perplexity и семи бенчмаркам на двух размерах модели, кривые «качество – бюджет вычислений», доверительные интервалы и дистилляционный контроль. Итог: внимание первых трёх слоёв заменяется окном со стоком за 1.5–1.8 % PPL без потерь на бенчмарках; MLP первых слоёв — лишь частично, лучший метод — наш предиктор активных нейронов M-O4 (4.7 % на 0.6B, 1.7 % на 1.7B при четверти вычислений MLP).

6. Ловушка калибровки в замкнутой форме: единичные токены с массивной активацией доминируют в задаче наименьших квадратов и обрушивают модель на слое, где возникает сток внимания. Мы даём формулу влияния строки, воспроизводим эффект дозой отравленных окон, устраняем его исключением строк-выбросов и показываем, какие опубликованные методы ему не подвержены и почему.

7. Нейроны стока: массивную активацию создают один–пять нейронов MLP, без которых модель не работает; их сохранение — обязательное условие любого отбора нейронов в ранних слоях.

8. Карта заменяемости по глубине и априорный критерий: дешёвые статистики слоя предсказывают KL его замены с ранговой корреляцией 0.9–0.97, воспроизводятся на второй модели и позволяют планировать замены на непросмотренной модели в 10–15 раз точнее замены префикса.

Структура статьи. Раздел 2 содержит обзор литературы. В разделе 3 описаны постановка, адаптированные методы из литературы и предложенные методы. Раздел 4 описывает экспериментальную установку, раздел 5 — результаты, раздел 6 — обсуждение и ограничения.

2 Обзор литературы

Обзор охватывает пять направлений: (1) архитектуру Transformer и её теоретические свойства; (2) механистическую интерпретируемость, которая объясняет, *что* вычисляют отдельные слои; (3) недавнюю дискуссию о том, являются ли нейросети «уже чистыми»; (4) методы эффективной аппроксимации самовнимания; (5) сжатие и разреженность слоёв MLP. В конце сформулированы выводы для нашей работы.

2.1 Архитектура Transformer и её свойства

Архитектура Transformer [2] отказалась от рекуррентности и свёрток в пользу многоголового масштабированного скалярного внимания $\mathrm{softmax}(QK^\top/\sqrt{d})V$, дополненного позиционным кодированием, остаточными связями и поэлементными слоями прямого распространения (MLP). Именно квадратичная по длине последовательности стоимость внимания мотивирует методы из раздела 2.4.

Два теоретических результата важны для понимания того, как устроены слои. Dong и др. [5] раскладывают выход сети из одних слоёв внимания на сумму путей и доказывают, что без остаточных связей и MLP такая сеть дважды экспоненциально по глубине сходится к матрице ранга 1. Остаточные связи этому препятствуют, а MLP замедляет вырождение. Отсюда следует, что остаточный поток — ключевой элемент любой послойной декомпозиции. Cordonnier и др. [4] показывают, что многоголовое самовнимание с относительным позиционным кодированием способно точно выразить любой свёрточный слой (ядро $\sqrt{N_h} \times \sqrt{N_h}$ при N_h головах). Эксперименты на изображениях подтверждают, что обученные головы действительно выучивают сеточные, свёрточные паттерны вокруг текущей позиции.

Значение для нашей работы: позиционные головы внимания можно описывать фиксированными ядрами [4], а заменять следует блок целиком, сохраняя остаточный поток [5].

2.2 Механистическая интерпретируемость

Программная работа «Zoom In» [8] формулирует три гипотезы: признаки (features) — базовые единицы нейросетей; признаки, связанные весами, образуют схемы (circuits); схожие признаки и схемы возникают в разных моделях (универсальность). На примере InceptionV1 разобраны детекторы кривых и другие схемы. Там же введено понятие полисемантических нейронов и приведён пример, который позже трактовался как суперпозиция.

Elhage и др. [1] переносят этот подход на трансформеры. Остаточный поток рассматривается как линейный канал связи, головы внимания — как независимые аддитивные компоненты с QK-схемой (куда смотреть) и OV-схемой (что переносить). Для моделей только из внимания получены точные описания: модель без слоёв реализует статистику биграмм, однослойная — биграммы и «skip-триграммы», а двухслойная за счёт композиции голов строит индукционные головы. Olsson и др. [23] показывают, что индукционные головы (паттерн $[A][B]\ldots[A] \rightarrow [B]$) появляются в ходе обучения скачкообразно, в «фазовом переходе», совпадающем с резким улучшением обучения в контексте. Для малых моделей связь доказана причинно, для больших приведены корреляционные свидетельства.

Geva и др. [3] интерпретируют слой MLP как память «ключ–значение»: ключи (строки первой матрицы) срабатывают на текстовые шаблоны, а значения задают распределения над словарём следующего токена. Принципиально для нас, что ключи *нижних* слоёв реагируют на поверхностные шаблоны (например, конкретные n-граммы), а верхних — на семантические.

Bricken и др. [24] обучают разреженный автокодировщик (словарное обучение) на активациях MLP однослойного трансформера. Получаются тысячи признаков, значительно более моносемантичных, чем исходные нейроны (например, признаки ДНК, арабского письма, base64), а с ростом словаря признаки «расщепляются» на более узкие. Rai и др. [25] дают практический обзор области: таксономию задач (изучение признаков, схем, универсальности), методов (probing, патчинг активаций, словарное обучение и др.) и открытых проблем.

Значение для нашей работы: есть точные описания вычислений для моделей глубины 0–1 [1], свидетельства «поверхностности» ранних MLP [3] и естественная граница сложности — композиция слоёв, порождающая индукционные головы [23].

2.3 Дискуссия «Neural networks are already clean»

В эссе Cammarata [6] (Goodfire, 2026; автор называет его «рабочей гипотезой») утверждается, что каноническое свидетельство полисемантичности и суперпозиции было неверно истолковано. Неинтерпретируемость поздних слоёв InceptionV1 объясняется не суперпозицией, а архитектурными проблемами и слабыми инструментами. После обычных улучшений обучения 99–100% нейронов последнего слоя становятся интерпретируемыми. Полисемантичность в основном объясняется мотивом «рекурсивного обобщения», то есть объединением *связанных* понятий. По предварительной оценке для Qwen3-32B около 90% «полюсов» нейронов имеют одну основную функцию, около 7% — две связанные, и лишь 2–4% пока не объяснены. Вывод автора: сеть можно изучать напрямую, без промежуточной декомпозиции вроде разреженных автокодировщиков [24].

Gao [7] принимает главное наблюдение (полисемантичность переоценивали), но возражает, что совпадение активирующих примеров с шаблоном недостаточно для объяснения нейрона. Во-первых, из того, что все активирующие примеры подходят под шаблон, не следует, что каждый подходящий пример активирует нейрон. Во-вторых, важна величина активаций: по его данным, обнуление слабых активаций заметно ухудшает модель. Gao предлагает критерий: объяснение верно, если подстановка *смоделированных* по нему активаций вместо настоящих не увеличивает KL-дивергенцию выходного распределения модели на большом корпусе. Кроме того, понимание отдельных нейронов не даёт понимания вычислений *между* ними: найденные схемы остаются большими и избыточными.

Обзорная заметка IBM Think [10] пересказывает эссе и собирает мнения исследователей: разметка нейронов не равна пониманию модели; пики активаций покрывают малую долю срабатываний; словарное обучение остаётся полезным для слабых активаций; нужны интервенционные эксперименты. Работа Lissack [9], судя по названию («Already Clean, Not Yet Meaningful»), разводит «чистоту» внутренних механизмов и их содержательную осмысленность. [TODO: прочитать текст: PhilArchive не отдаёт страницу автоматически]

Значение для нашей работы: задача замены первых слоёв явным алгоритмом — это конструктивная проверка тезиса о «чистоте» на уровне целых слоёв. Критерий Gao (downstream KL при подстановке) совпадает с нашей основной метрикой качества аппроксимации, а его замечание о слабых активациях указывает на главный риск табличных аппроксимаций.

2.4 Эффективные аппроксимации внимания

2.4.1 Ядерные и линейные методы

Katharopoulos и др. [11] заменяют $\exp(q^\top k)$ на скалярное произведение признаковых отображений $\phi(q)^\top \phi(k)$ с $\phi(x) = \mathrm{elu}(x) + 1$. Ассоциативность матричного произведения даёт сложность $O(n)$, а авторегрессионная модель становится рекуррентной сетью с постоянной памятью на шаг. Performer [14] (механизм FAVOR+) строит *несмещённую* оценку softmax-ядра положительными ортогональными случайными признаками и доказывает оценки её точности. RFA [15] аппроксимирует softmax-ядро случайными фурье-признаками и добавляет механизм гейтинга для смещения внимания к недавним токенам. SOFT [16] отказывается от softmax в пользу гауссова ядра, что позволяет построить детерминированное низкоранговое разложение с опорными точками. Псевдообратная матрица при этом вычисляется итерациями Ньютона–Рафсона.

2.4.2 Низкоранговые методы

Linformer [12] опирается на наблюдение, что матрица внимания имеет низкий эффективный ранг, и проецирует K и V по оси последовательности обучаемыми матрицами в размерность $k \ll n$.

Nyströmformer [13] аппроксимирует softmax-матрицу методом Нистрёма с опорными точками, выбранными как средние по сегментам последовательности, то есть детерминированно. A3 [22] — метод сжатия *после обучения*: слой разбивается на функциональные компоненты QK, OV и MLP, и для каждого аналитически находится уменьшение скрытой размерности, минимизирующее функциональную ошибку компонента. В отличие от разложения весовой матрицы на два сомножителя, это не добавляет накладных расходов при выводе. На LLaMA 3.1-70B метод заметно превосходит предыдущие низкоранговые подходы по perplexity при равном бюджете.

2.4.3 Разреженные шаблоны внимания

Sparse Transformer [17] использует фиксированные факторизованные (strided и fixed) шаблоны со сложностью $O(n\sqrt{n})$ и моделирует последовательности длиной в десятки тысяч элементов. Reformer [18] группирует близкие запросы и ключи локально-чувствительным хешированием (случайные повороты), получая $O(n \log n)$, и экономит память обратимыми остаточными слоями. BigBird [19] комбинирует локальное окно, глобальные токены и случайные рёбра и доказывает, что такое разреженное внимание сохраняет универсальность аппроксимации и полноту по Тьюрингу.

2.4.4 Замена внимания

FNet [20] заменяет подслой самовнимания непараметрическим двумерным дискретным преобразованием Фурье и достигает 92–97% точности BERT на GLUE при существенно более быстром обучении. Synthesizer [21] показывает, что веса внимания можно синтезировать без попарного взаимодействия токенов: по каждому токену в отдельности (Dense) или вообще независимо от входа (Random). Такие модели остаются конкурентоспособными на ряде задач.

2.4.5 Сводка

Метод	Способ аппроксимации	Случайность	Нужно обучение
Linear Attention [11]	ядро elu + 1	нет	да
Performer [14]	случайные ортогональные признаки	да	да
RFA [15]	случайные фурье-признаки	да	да
SOFT [16]	гауссово ядро + низкий ранг	нет	да
Linformer [12]	обучаемые проекции по длине	нет	да
Nyströmformer [13]	метод Нистрёма, сегментные средние	нет	да
A3 [22]	аналитическое снижение ранга QK/OV/MLP	нет	**нет**
Sparse Transformer [17]	фиксированные разреженные шаблоны	нет	да
Reformer [18]	LSH-хеширование	да	да
BigBird [19]	окно + глобальные + случайные рёбра	да	да
FNet [20]	преобразование Фурье	нет	да
Synthesizer [21]	синтезированные веса внимания	нет	да

Таблица 1: Методы эффективного внимания. «Нужно обучение»: метод предполагает обучение модели с нуля или дообучение, а не построение по весам готовой модели.

2.5 Сжатие и разреженность слоёв MLP

Слой MLP в современных LLM (в Qwen3 — SwiGLU, $\mathrm{down}(\mathrm{silu}(W_g x) \odot W_u x)$) содержит большую часть параметров блока. Для его ускорения после обучения есть два подхода.

Низкоранговые разложения с учётом активаций. Простое SVD весовой матрицы плохо работает для LLM из-за выбросов в активациях. ASVD [26] масштабирует столбцы весовой матрицы по статистике активаций, так что выбросы «поглощаются» весами перед разложением, и подбирает

ранг послойно с учётом чувствительности слоёв. Без обучения это сжимает сеть на 10–30%. SVD-LLM [27] предлагает «отбеливание» данных, согласованное с усечением: после него каждое отброшенное сингулярное число напрямую соответствует потере на калибровочных данных. Затем сжатые веса дообучаются последовательной низкоранговой аппроксимацией. Первая часть — замкнутая форма, вторая требует градиентного обучения. Эти методы применимы к любым линейным проекциям, включая проекции внимания. Отбор нейронов MLP в A3 [22] относится к той же группе: это детерминированный критерий в замкнутой форме.

Разреженность активаций. MoEfication [29] исходит из наблюдения, что на каждом входе активна малая доля нейронов FFN. Метод разбивает нейроны на группы-«эксперты» и строит маршрутизатор, выбирающий группы для входа. В итоге используется 10–30% параметров FFN при сохранении более 95% исходного качества. Deja Vu [28] обобщает идею до «контекстной разреженности»: для каждого входа существует малое подмножество голов внимания и нейронов MLP, дающее почти тот же выход. Это подмножество предсказывается лёгким обучаемым предиктором и используется для ускорения вывода больших моделей более чем в два раза. Обе работы опираются на интерпретацию MLP как памяти «ключ–значение» [3]: на конкретном входе срабатывают немногие ключи.

Значение для нашей работы: для MLP первых слоёв сравниваем детерминированные части этих методов: разложения ASVD и SVD-LLM без дообучения, разбиение MoEfication с маршрутизацией без обучения, «оракульную» контекстную разреженность как верхнюю границу для Deja Vu. Их обучаемые компоненты (дообучение SVD-LLM, предиктор Deja Vu) оцениваем только в отдельном треке с дистилляцией.

2.6 Выводы и место нашей работы

1. Методы эффективного внимания применяют *одну и ту же* аппроксимацию во всех слоях и, за исключением A3 [22], требуют обучения. Зависимость качества аппроксимации от глубины слоя в них не исследуется.

2. Значительная часть методов стохастична ([14, 15, 18, 19]). Детерминированные альтернативы ([13, 16, 17, 20]) существуют, но не сравнивались с ними именно как post-hoc замена слоёв обученной модели.

3. Интерпретируемость даёт основания считать первые слои простыми: биграммы и skip-триграммы [1], поверхностные шаблоны в MLP [3], свёрточные позиционные паттерны [4]. Однако эти наблюдения не превращены в работающий алгоритм, который заменял бы слои целиком.

4. Методы сжатия MLP [26, 27, 29, 28] оценивают качество на всей модели при равномерном сжатии слоёв. Вопрос, насколько полно MLP *первых* слоёв заменяется таблицами и линейными картами в замкнутой форме, остаётся открытым.

5. Разреженность активаций без обучения (CATS [30], TEAL [31]) отбирает нейроны порогом по величине активации и оценивается на всей модели; её поведение в первых слоях отдельно не изучалось. Удаление блоков с линейной заменой на границе (ShortGPT-подобный выбор блока, ReplaceMe [32], Ghosted Layers [33]) использует регрессию на остаточном потоке — ту же конструкцию, что и наши калибровки, и потому подвержено той же ловушке.

6. Массивные активации [35] и «супервеса» [34] описаны как свойство обученных моделей и как источник трудностей квантования; их влияние на статистики пост-хок калибровки структурных замен и на отбор нейронов ранних слоёв до сих пор не рассматривалось.

7. Дискуссия о «чистоте» нейросетей [6, 7] даёт и мотивацию, и критерий проверки: явная замена слоёв, оцениваемая по downstream KL, — строгая форма утверждения «мы понимаем, что делают эти слои».

Наша работа закрывает этот пробел: мы строим детерминированные алгоритмы, заменяющие первые k слоёв обученной LLM без дообучения, и определяем глубину k^*, до которой такая замена возможна.

3 Методы

3.1 Обозначения и постановка

Блок Qwen3 [2] с предварительной нормализацией действует на остаточный поток $h \in \mathbb{R}^{T\times d}$ как

$$h' = h + \mathrm{Attn}(\hat{x}), \quad \hat{x} = \mathrm{RMSNorm}(h), \qquad h'' = h' + \mathrm{MLP}(\hat{x}'), \quad \hat{x}' = \mathrm{RMSNorm}(h').$$

Внимание групповое (GQA): H голов запросов делят H_{kv} голов ключей и значений, размерность головы D. Запросы и ключи проходят нормализацию по размерности головы (QK-norm) и поворотное позиционное кодирование (RoPE): $q_t = \mathrm{RoPE}_t(\mathrm{RMSNorm}_q(W_q\hat{x}_t))$, $k_j = \mathrm{RoPE}_j(\mathrm{RMSNorm}_k(W_k\hat{x}_j))$, $v_j = W_v\hat{x}_j$, $a_{tj} = \mathrm{softmax}_{j\le t}(q_t^\top k_j/\sqrt{D})$. MLP имеет вид SwiGLU: $\mathrm{MLP}(x) = W_d\, z(x)$, $z(x) = \mathrm{silu}(W_g x)\odot W_u x \in \mathbb{R}^I$.

Заменяются слои $0,\dots,k-1$. Различаем три вида замены: только подслой внимания (MLP точный), только MLP (внимание точное) и блок целиком. Детерминированный метод строится по весам и по калибровочному набору $\mathcal{C}$ (фрагменты WikiText-103) в замкнутой форме: средние, ковариации, SVD, гребневая регрессия и поочерёдная минимизация (backfitting). Стохастическая аппроксимация и градиентное обучение в основном треке не используются.

Позиция 0. В каузальной модели состояние первого токена зависит только от самого токена, а любая нормированная строка внимания при $t = 0$ даёт ровно $W_o v_0$. Поэтому замены внимания на позиции 0 точны автоматически. Для замен MLP и блоков мы вычисляем позицию 0 исходным слоем, что эквивалентно таблице по словарю из $|V|$ строк. Это существенно: в Qwen3 норма состояния первого токена вырастает на два–три порядка после нескольких первых слоёв (массивная активация, на которой держится сток внимания), и любая ошибка в ней разрушает модель.

3.2 Методы из литературы, адаптированные к Qwen3

Внимание. **L1** (окно + сток; Sparse Transformer [17], BigBird без случайных рёбер [19]): softmax вычисляется только по j с $t-j < w$ или $j = 0$. **L2** (strided [17]): дополнительно разрешены j с $(t-j) \bmod s = 0$. **L3** (Performer, FAVOR+ [14]): $\exp(q^\top k/\sqrt{D}) \approx \varphi(q')^\top\varphi(k')$, $q' = qD^{-1/4}$, $\varphi(x) = m^{-1/2}\exp(\Omega x - \|x\|^2/2)$ с блочно-ортогональной гауссовой $\Omega \in \mathbb{R}^{m\times D}$; это единственный стохастический метод сравнения, он запускается с тремя seed. **L4** (линейное внимание [11]): $\varphi(x) = \mathrm{elu}(x)+1$. **L5** (фиксированное внимание в духе Synthesizer [21]): a_{tj} зависит только от $t-j$: ядро $K_h(\delta)$ при $\delta < \Delta$, вес стока σ_h при $j = 0$, равномерный «хвост»; K_h и σ_h — средние точного внимания на $\mathcal{C}$, строки перенормируются. **L6** (A3 [22]). Код авторов поддерживает Llama и MPT, поэтому мы перенесли метод на Qwen3. QK: в каждой KV-группе оставляются $r/2$ пар RoPE $(i, i+D/2)$ с наибольшим $\sum_{h\in g}\sqrt{\mathbb{E}q_{h,i}^2}\sqrt{\mathbb{E}k_{g,i}^2}$; моменты берутся после QK-norm, что совпадает с критерием A3 $\|R^{1/2}w_q\|\,\|w_k R^{1/2}\|$ для линейных проекций. VO: для группы g строится $M_g = [W_{v,g}^\top W_{o,h}^\top]_{h\in g}$ и усечённое SVD $R^{1/2}M_g = U\Sigma V^\top$, где $R = \mathbb{E}\,\hat{x}\hat{x}^\top$. Мы полагаем $W_v'^\top = M_g V_r$, $W_o' = V_r^\top$. Произведение $M_g V_r V_r^\top$ совпадает с решением A3 при обратимой R, но не требует $R^{-1/2}$, которая на реальных данных плохо обусловлена. FFN: оставляются нейроны с наибольшим $\sqrt{\mathbb{E}z_i^2}\,\|w_{d,i}\|$.

MLP. **ML1** — отбор нейронов A3 (см. выше). **ML2** — «оракульная» контекстная разреженность Deja Vu [28]: на каждом токене используются κ нейронов с наибольшим $|z_i|$. Это верхняя граница для обучаемого предиктора Deja Vu и одновременно разреженность памяти «ключ–значение» [3]. **ML4** — ASVD [26]: $S = \mathrm{diag}(\mathbb{E}|x|)^\alpha$, $W \approx (U_r\Sigma_r)(V_r^\top S^{-1})$ по SVD матрицы WS, $\alpha = 0.5$. **ML5** — SVD-LLM [27] без шага дообучения: $\mathbb{E}\,xx^\top = LL^\top$ (Холецкий), $W \approx U_r\Sigma_r V_r^\top L^{-1}$ по SVD матрицы

WL. Для $W \in \mathbb{R}^{m\times n}$ и доли параметров ρ ранг $r = \lfloor \rho mn/(m+n) \rfloor$; сжимаются W_g, W_u, W_d. **ML7** — MoEfication [29]: нейроны разбиваются сбалансированным k-means (детерминированная инициализация k-means++) по нормированным строкам $[W_g; W_u]$ на E экспертов; маршрутизация без обучения выбирает m экспертов с наибольшим $\hat{x}^\top c_e$, где c_e — центроид строк W_g эксперта.

Неприменимые методы. Linformer [12] проецирует ключи и значения по оси последовательности обучаемыми матрицами. Nyströmformer [13] строит опорные точки как средние по сегментам всей последовательности, FNet [20] применяет ДПФ ко всем позициям. В каузальной модели все три метода смешивают будущие токены с прошлыми, и маскирование после факта не восстанавливает каузальность. SOFT [16] заменяет softmax гауссовым ядром, Reformer [18] требует общей проекции QK и случайного хеширования; оба предполагают обучение с нуля.

3.3 Предложенные методы

O1: типизированная замена голов. Для каждой головы вычисляется расстояние полной вариации $\mathrm{TV}_h = \mathbb{E}_t \frac{1}{2}\|a_{t\cdot} - \tilde{a}_{t\cdot}\|_1$ между точным вниманием и позиционным ядром L5 (на калибровке). Доля ρ голов с наименьшим TV_h заменяется ядром, остальные считаются точно (или в окне w). Ядро не требует вычисления $q^\top k$.

O2: ридж-свёртка вместо внимания. Подслой внимания заменяется каузальной линейной свёрткой в пространстве p главных компонент P входа: $\mathrm{Attn}(\hat{x})_t \approx \sum_{\delta<w} W_\delta P^\top \hat{x}_{t-\delta} + W_s P^\top \hat{x}_0 + b$. Коэффициенты находятся гребневой регрессией.

O3: аддитивная n-граммная замена блоков. Выход первых k блоков при $t \geq 1$ приближается суммой таблиц по токенам окна и позиционного члена: $h_{k,t} \approx e(x_t) + \sum_{\delta<m} T_\delta[x_{t-\delta}] + \pi[\min(t, P)]$. Таблицы подгоняются поочерёдной минимизацией (backfitting) со сжатием $T[v] = \sum r/(n_v + \lambda)$. Вычисление первых k слоёв заменяется m обращениями к таблице.

O4: позиционное ядро $\times$ значимость ключа. Профиль (раздел 5) показывает, что внимание первых слоёв *контентное*: позиционное ядро объясняет его хуже, чем в средних слоях. Мы добавляем к ядру множитель, зависящий от токена-ключа:

$$a_{tj} \;\propto\; K_h(t-j)\,\exp\big(\beta_h(x_j)\big), \quad j \geq 1; \qquad a_{t0} \propto \sigma_h.$$

Таблица β_h подгоняется итеративным согласованием маргиналов (IPF): $\beta_h(v) \leftarrow \beta_h(v) + \log \frac{A_h^{\text{true}}(v)+\alpha}{A_h^{\text{model}}(v)+\alpha}$, где $A_h(v)$ — суммарная масса внимания, полученная ключами с токеном v на $\mathcal{C}$. Как и L5, метод не вычисляет $q^\top k$, но улавливает головы, смотрящие на определённые токены (пунктуацию, служебные слова). В гибридном варианте доля голов с наибольшей остаточной TV-ошибкой считается точно (при необходимости в окне w).

M-O1: линеаризация MLP с точными нейронами. $\mathrm{MLP}(\hat{x}) \approx W\hat{x} + b + \sum_{i\in S} w_{d,i} z_i(\hat{x})$, где S — r нейронов по критерию A3, а W, b — гребневая регрессия на остаток. При $S = \varnothing$ MLP заменяется одной линейной картой (d^2 параметров вместо $3dI$).

M-O4: предиктор активных нейронов в замкнутой форме. Контекстная разреженность Deja Vu [28] использует обучаемый предиктор активных нейронов. Мы заменяем его гребневой регрессией: вклад нейрона $|z_i(\hat{x})|\,\|w_{d,i}\|$ предсказывается линейно из $p = 64$ главных компонент входа, $\widehat{c}(\hat{x}) = (\hat{x}P)A$. На каждом токене вычисляются только κ нейронов с наибольшим $\widehat{c}_i$, а остаток MLP компенсируется линейной картой $W\hat{x}+b$, подогнанной на остаток. Стоимость — $3d\kappa + d^2 + p(d+I)$ умножений вместо $3dI$. Вариант с таблицей $N[x_t]$ (набор нейронов только по текущему токену) заметно хуже: активность нейронов первых слоёв зависит от контекста.

O5: окно + детерминированный хвост. Внутри окна w и на стоке оценки $q^\top k$ точные, для дальних ключей оценка заменяется таблицей $\beta_h(x_j)$, подогнанной IPF по массам внимания. Хвост вычисляется префиксными суммами за $O(T)$. Инициализация β лог-средним $\exp(s)$ завышает массу хвоста (неравенство Йенсена) и ухудшает качество в разы; со средним s и IPF метод сравним с простым окном того же размера. Это указывает, что дальний контекст в первых слоях почти не используется.

M-O2 и M-O3. Табличный MLP: $\mathrm{MLP}(\hat{x}_t) \approx T[x_t] + W\hat{x}_t + b$ (поочерёдная подгонка таблицы и линейной части). Кусочно-линейный MLP: k-means в пространстве главных компонент входа и своя гребневая карта в каждом кластере.

Последовательная калибровка с компенсацией дрейфа. Все наши методы подгоняются слой за слоем. Признаки слоя i вычисляются по пути «ученика», в котором слои $< i$ уже заменены, а целью служит состояние учителя: $y = h^T_{i+1} - h^S_{i,\mathrm{mid}}$. Тем самым каждый заменённый слой не только аппроксимирует свой исходный, но и возвращает остаточный поток к траектории исходной модели. Методы из литературы калибруются один раз по пути исходной модели, как в оригинальных работах.

3.4 Дистилляционный контроль

Чтобы сравнить с методами, которые в оригинале обучаются (линейное внимание, шаг дообучения SVD-LLM), и оценить запас наших методов, мы отдельно дообучаем параметры замен AdamW (300 шагов) на потерю $\mathbb{E}_t\|h^S_{k,t} - h^T_{k,t}\|^2/\|h^T_{k,t}\|^2$. Эти результаты не детерминированы в смысле введения и в таблицах помечены отдельно.

4 Экспериментальная установка

Модели. Qwen3-0.6B и 1.7B в варианте Base. Обе модели используют классическое softmax-внимание с GQA, QK-нормализацией и RoPE. Модели Qwen3.5 малых размеров не подходят: в них три из четырёх слоёв — линейное внимание Gated DeltaNet, и первые слои не содержат softmax-внимания. Мы не обучаем модели заново, а берём опубликованные веса. Исходная модель (столбец «Исх.») проверяется по тем же бенчмаркам. Второе семейство — архитектура Llama без QK-нормализации и со связанными эмбеддингами: SmolLM2-1.7B (24 слоя, $d = 2048$, $I = 8192$, 32 головы MHA) и Llama-3.2-1B (16 слоёв, $d = 2048$, $I = 8192$, GQA 32/8). На них повторён полный протокол: профиль, таблица при $k = k_{\mathrm{sink}}$, кривые по k, карта, обрыв, ловушка, нейроны стока, CATS, планировщик и механизм MLP.

Данные. Все тексты для калибровки и оценки — набор WikiText [36]: статьи англоязычной Википедии категорий Good и Featured, собранные и опубликованные Salesforce Research (вариант `raw`, без замены редких слов; HF `Salesforce/wikitext`). Калибровка — WikiText-103 train (103 млн слов): из первых ≈2.1 млн символов корпуса с фиксированным seed берутся 256 случайных неперекрывающихся окон по 512 токенов (131 072 токена; для табличных методов 1–2 млн), окна вырезаются из сплошного текста без начального токена. Оценка — WikiText-2 test (≈245 тыс. слов): первые 32 неперекрывающихся окна по 1024 токена (32 736 предсказаний). Обучающая часть WikiText-103 и тест WikiText-2 не пересекаются. Токенизация — собственный токенизатор каждой модели (Qwen3: 151 936 токенов). Для проверки переноса на другой домен используется pile-10k — 10 тыс. документов из The Pile [37]. Бенчмарки берутся из lm-evaluation-harness [38] в стандартной постановке (ранжирование вариантов ответа по логарифму правдоподобия): LAMBADA [39] (5 153 отрывка), HellaSwag [40] (10 042), ARC-Easy/Challenge [41] (2 376/1 172), PIQA [42] (1 838), WinoGrande [43] (1 267) и MMLU [44] (14 042 вопроса по 57 предметам); на ноутбуке используются подвыборки (см. ниже).

Метрики. Основная — средняя на токен $\mathrm{KL}(p_f \,\|\, p_{\tilde{f}})$ между исходной и изменённой моделью, критерий «KL при подстановке» [7]. Дополнительно: perplexity, доля совпадения наиболее вероятного токена (top-1) и относительная ошибка остаточного потока после слоя k. Обе модели считаются в одном процессе в fp32: в bf16 расхождение двух реализаций одного и того же внимания уже даёт $\mathrm{KL} \approx 10^{-3}$, а в fp32 вырожденные режимы всех методов дают $\mathrm{KL} < 10^{-8}$. Бенчмарки (lm-eval 0.4.13, bf16): LAMBADA, HellaSwag, ARC-e, ARC-c, PIQA, WinoGrande (0-shot, по 200 примеров) и MMLU (5-shot, по 5 вопросов на подзадачу, 285 вопросов).

Глубина замены. $k \in \{1, 2, 3, 4, 6\}$ для развёртки по глубине на 0.6B. Для итоговых таблиц используется $k = k_{\text{sink}}$: число первых слоёв до появления массивной активации первого токена (норма больше медианы в 100 раз). Эта глубина определяется автоматически по профилю каждой модели.

Бюджет. Для MLP указывается доля параметров и доля умножений на токен относительно исходного $3dI$. Для внимания — доля голов или позиций, для которых вычисляется $q^\top k$. Наши реализации эталонные (материализуют матрицу $T \times T$), поэтому время работы не измеряется: сравнение проводится по асимптотике и числу операций.

Вычисления и воспроизводимость. Все вычисления выполнены на ноутбуке с Apple M4 (16 ГБ, MPS). Модели 4B и 8B в fp32 в эту память не помещаются, поэтому исследование ограничено 0.6B и 1.7B. PyTorch 2.15, transformers 5.22, lm-eval 0.4.13. Все случайные выборки (калибровочные окна, инициализация k-means, признаки Performer) фиксированы seed. Код, конфигурации и сырые JSON-результаты прилагаются.

5 Результаты

5.1 Профиль слоёв

На Qwen3-0.6B первые три слоя образуют отдельный режим (рис. 1). В слоях 0–2 сток внимания практически отсутствует: доля массы на позиции 0 составляет 0.3–1.3% против 32–77% в последующих слоях. Норма состояния первого токена выросла с $\approx$20 до $\approx$7000 к моменту входа в слой 3. Поэтому $k_{\text{sink}} = 3$. Вопреки исходной гипотезе о «позиционных» первых слоях, расстояние до позиционного ядра в слоях 0–2 наибольшее (TV $\approx$ 0.42–0.50 против 0.30 в среднем по слоям 3–27, разброс 0.17–0.44): внимание первых слоёв в основном контентное. Это мотивирует метод O4. На Qwen3-1.7B картина та же: $k_{\text{sink}} = 3$, норма первого токена достигает $\approx$14 700 на входе слоя 3.

5.2 Случайные признаки неприменимы к первым слоям

Дисперсия оценки FAVOR+ растёт как $\exp(\|x + y\|^2)$. Для $m = 4096$ признаков медианная относительная ошибка равна 2% при $\|x\|\sqrt{s} = \|y\|\sqrt{s} = 1$, 21% при 2, 69% при 3 и $\approx$100% начиная с 4. У Qwen3-0.6B после QK-нормализации медианная масштабированная норма ключей в слоях 0–2 равна 32–60, запросов — 4.5–8 (рис. 2). Оценка ядра в этой области бессмысленна, и замена внимания Performer без переобучения разрушает модель. Мы проверили, что реализация несмещённая при малых нормах, то есть это свойство модели, а не ошибка кода.

5.3 Зависимость от глубины замены

Окно со стоком деградирует плавно: 0.2, 0.9, 1.8, 3.3, 4.8, 7.5 и 13.9 % при $k = 1, 2, 3, 4, 6, 8, 12$, то есть первые три слоя внимания заменяются в пределах 2 %, первые шесть — в пределах 5 %, и даже при замене почти половины слоёв потеря остаётся умеренной. Отбор 25 % нейронов по готовым активациям ведёт себя похоже (0.6 — 10.2 %), но экономит лишь последнюю матрицу MLP. SVD-LLM и O1 разваливаются быстро: 12.8 и 23.7 % уже при $k = 3$, более 50 % при $k = 8$. Наивно откалиброванный M-O4 демонстрирует немонотонность с пиком при $k = k_{\text{sink}} = 3$; её причина и

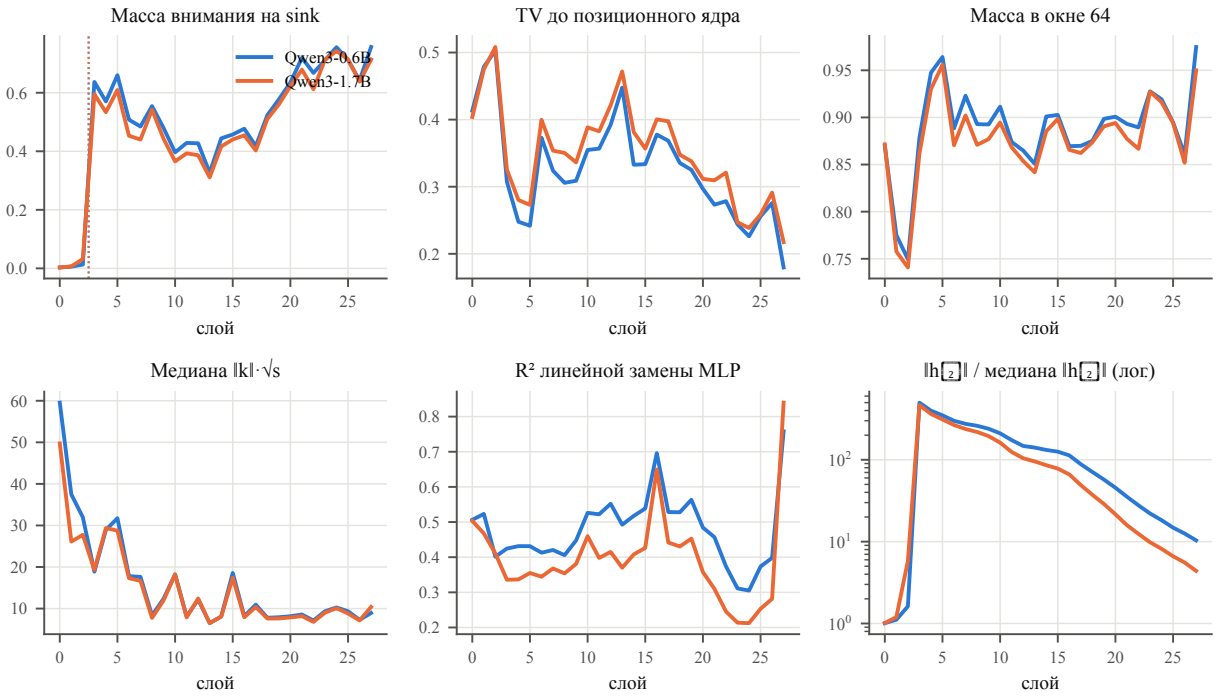


Рис. 1: Послойный профиль Qwen3. Масса внимания на стоке (позиция 0); расстояние полной вариации до позиционного ядра (меньше — позиционнее); доля массы внимания в окне 64; медианная масштабированная норма ключей; R^2 линейной замены MLP на отложенных данных; отношение нормы первого токена к медиане остальных. Пунктир — k_{sink}.

устранение — в разд. 6, после чего M-O4 удерживает 5 % до $k = 3$ и остаётся лучшим из методов с предсказанием нейронов до их вычисления.

5.4 Качество и бюджет вычислений

Ширина окна при $k = 3$ задаёт плавный компромисс: 8, 16, 32, 64 и 128 позиций дают рост PPL 6.3, 4.1, 2.9, 1.8 и 1.0 %, то есть каждое удвоение окна снимает около трети ошибки; 64 — колено кривой, которое мы и используем. Для MLP отбор по вкладу нейрона при 5, 10, 25 и 50 % активных даёт 16.9, 6.8, 2.2 и 0.3 %; робастный M-O4 с предсказанием нейронов — 10.2, 7.8, 4.7 и 2.5 % при стоимости 0.28–0.55 MLP; SVD-LLM при ранге 10–75 % — от 41.5 до 5.8 %; A3 FFN — от 10^3 % при 10 % нейронов до 3.1 % при 75 %; ASVD и MoEfication уступают всем. Для внимания половина голов, заменённых позиционным ядром (O1), стоит 23.7 %, четверть — 2.9 %, три четверти — 67 %: позиционными являются лишь немногие головы первых слоёв.

5.5 Единый обменный курс

На рис. 5 все работающие детерминированные замены Qwen3-0.6B ложатся около линии «один процент PPL за один процент вычислений»: окно при $k = 3$ (1.7 % экономии за 1.8 %), робастный M-O4 при $k = 3$ ($\approx$ 4.6 за 4.7 %), линейный призрак двух средних слоёв (6.5 за 6.2 %). Методы с ошибочным критерием — SVD-LLM, CATS, призраки по косинусному критерию ShortGPT — лежат в разы выше. У Qwen3-1.7B курс лучше примерно в 2.5 раза: те же замены стоят 0.4 % PPL за процент вычислений. Это основной аргумент в пользу проверки на моделях 4B–32B: если курс продолжает улучшаться с размером, замена первых слоёв становится выгодной именно там, где важна.

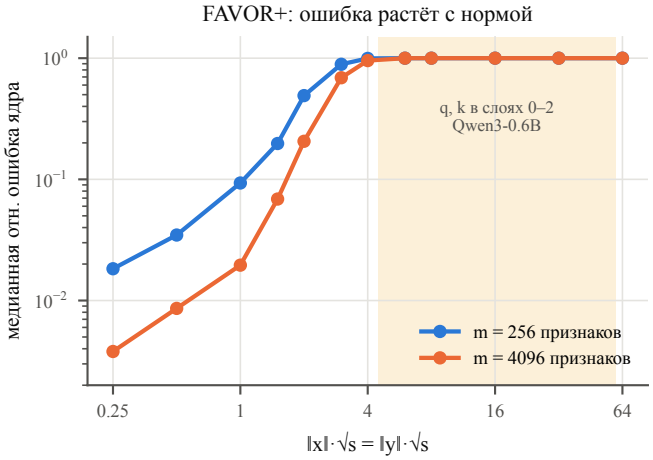


Рис. 2: Медианная относительная ошибка оценки $\exp(x^\top y)$ признаками FAVOR+ в зависимости от нормы входа ($D = 128$, 64 пары на точку, ошибка ограничена сверху единицей). Закрашенная область — нормы запросов и ключей в слоях 0–2 Qwen3-0.6B.

	Исх.	Окно	Окно$_m$	Поз.	A3	SVD-LLM	Окно+SVD	O1	M-O4	M-O4г	Окно+M-O4г
Что заменено	—	вним.	вним.	вним.	блок	MLP	блок	вним.	MLP	MLP	блок
Доля вычислений MLP	1.00	1.00	1.00	1.00	0.50	0.50	0.50	1.00	0.39	0.39	0.39
PPL WikiText-2 ↓	14.06	14.32	14.32	84.26	20.98	15.85	16.08	17.39	17.86	14.72	14.79
KL к исходной ↓	0.000	0.016	0.016	1.805	0.433	0.138	0.151	0.226	0.268	0.056	0.065
Совпадение top-1 ↑	100.0	94.7	94.7	43.4	71.6	85.4	84.3	80.3	76.1	90.5	89.4
LAMBADA ↑	53.5	55.0	55.0	14.5	36.5	46.0	46.0	—	32.5	51.0	51.5
HellaSwag ↑	53.0	53.5	53.5	47.0	47.5	53.0	53.0	—	48.5	54.0	53.0
ARC-e ↑	55.5	57.5	57.5	49.5	54.0	61.0	61.0	—	57.0	58.0	57.0
ARC-c ↑	36.0	37.0	37.0	28.5	30.0	35.0	35.0	—	31.0	37.0	38.0
PIQA ↑	72.0	70.5	70.5	61.0	64.5	67.5	68.0	—	64.0	69.0	68.0
WinoGrande ↑	63.0	63.0	63.0	58.0	57.0	59.0	59.5	—	53.5	64.5	65.5
MMLU (5-shot) ↑	51.6	50.9	51.6	29.1	37.2	48.8	46.0	—	24.6	48.8	47.0
Среднее по бенчам ↑	54.9	55.3	55.4	41.1	46.7	52.9	52.6	—	44.4	54.6	54.3

Таблица 2: Qwen3-0.6B-Base, замена первых k_{sink} слоёв. Столбцы: исходная модель; методы из литературы (окно+сток, позиционное внимание, A3, SVD-LLM, окно+SVD-LLM); предложенные (O1, M-O4 с наивной и робастной калибровкой, окно+M-O4 робастный). Бенчмарки — точность, %, подвыборки по 200 примеров (MMLU — 5 на подзадачу).

5.6 Призраки блоков: где удалять слои

Линейная замена блока из n подряд идущих слоёв (ReplaceMe [32]) требует выбрать блок. Критерий ShortGPT — косинусная близость входа и выхода слоя — на Qwen3-0.6B выбирает слои 24–25 и 23–26; их удаление стоит $+85$ и $+1760$ % PPL, а линейная карта на границе снижает это лишь до 27 и 77 %. Выбор по нашей карте (минимальный KL одиночного удаления) даёт слои 13–14 и 12–15: удаление $+13.6$ и $+37.5$ %, с полной линейной картой 6.2 и 16.4 %, с картой ранга 256 — 6.7 и 17.3 %. Карта заменяемости, построенная за один прогон одиночных замен, выбирает блок в 4–5 раз точнее косинусного критерия, а призрак двух средних слоёв по цене сопоставим с заменой MLP трёх первых.

5.7 Итоговая таблица

Статистическая значимость. На подвыборках по 200 примеров стандартная ошибка средней точности по семи задачам равна ± 2.5 п.п., на 1000 примерах — ± 1.1 п.п. (биномиальная оценка). На 1000 примерах окно при $k = 3$ даёт 54.7 против 54.5 % у исходной Qwen3-0.6B и 62.9 против 62.4 % у 1.7B — неотличимо от исходной модели. Робастный M-O4 на 0.6B теряет около пункта (53.5 %, на границе значимости), на 1.7B — нет (62.7 %); SVD-LLM теряет один–два пункта значимо (52.5 и

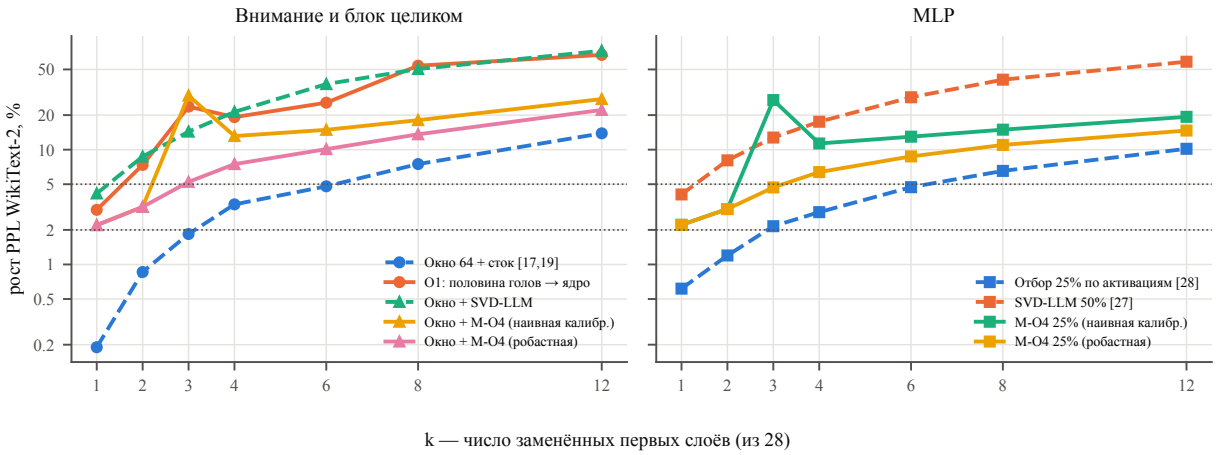


Рис. 3: Рост PPL WikiText-2 в зависимости от числа заменённых первых слоёв k (Qwen3-0.6B, 32 окна по 1024 токена, логарифмическая шкала; пунктирные линии — пороги 2 и 5 %). Пунктир с кружками — методы из литературы, сплошные с квадратами — предложенные; для M-O4 показаны наивная и робастная калибровка (разд. 6).

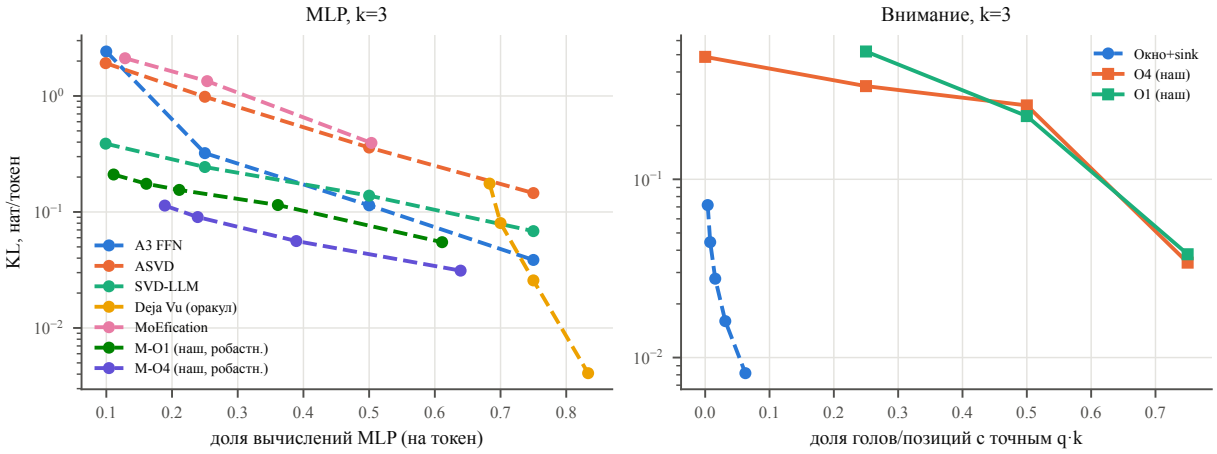


Рис. 4: KL в зависимости от бюджета при $k = k_{\text{sink}}$ (Qwen3-0.6B). Слева — методы для MLP (доля умножений на токен относительно исходного MLP), справа — методы для внимания (доля вычисляемых $q^\top k$).

61.5 %). Для PPL и KL 95 %-е интервалы по бутстрэпу окон на полном тесте WikiText-2 узки: окно 1.6 [1.5; 1.7] %, робастный M-O4 4.9 [4.6; 5.1] %, SVD-LLM 13.2 [12.6; 13.8] % на 0.6B; 1.7 [1.6; 1.8], 1.7 [1.5; 1.9] и 8.2 [7.7; 8.7] % на 1.7B (табл. 4). Все различия между главными столбцами значимы.

5.8 Длина контекста и число стоков

Ошибка окна растёт с длиной контекста медленно, примерно как логарифм T: при $k = 3$ она равна 1.81, 2.51, 3.21 и 4.89 % для $T = 1024$, 2048, 4096 и 8192 (табл. 5); четыре стока вместо одного помогают лишь при $T = 8192$ (4.49 %). Число стоков — один, два, четыре или сток вместе со всеми токенами перевода строки — на результат не влияет (разброс 0.03 п.п. при $k = 3$ и $k = 6$).

5.9 Перенос на другой корпус

Окно не калибруется и переносится без потерь: 1.2 % на pile-10k против 1.8 % на WikiText-2. Калиброванные замены MLP переобучаются под домен калибровки: при калибровке на WikiText-103

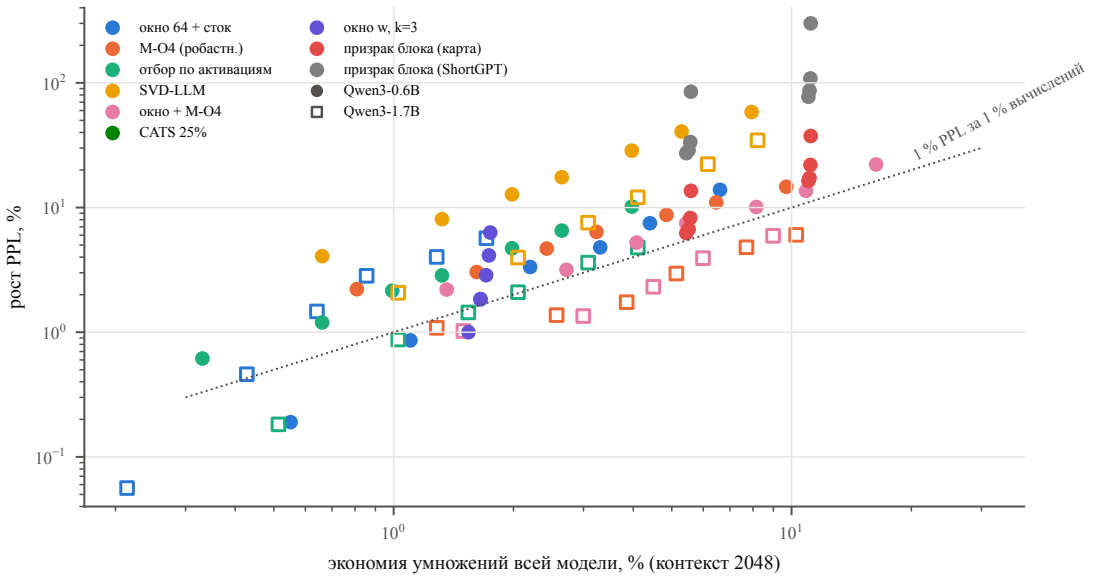


Рис. 5: Все замены на одной шкале: рост PPL против доли сэкономленных умножений всей модели при контексте 2048 (кривые по k, ширина окна, призраки блоков; закрашенные маркеры — Qwen3-0.6B, пустые — 1.7B). Пунктир — один процент PPL за один процент вычислений.

	Исх.	Окно	Окно$_m$	Поз.	A3	SVD-LLM	Окно+SVD	O1	M-O4	M-O4г	Окно+M-O4г
Что заменено	—	вним.	вним.	вним.	блок	MLP	блок	вним.	MLP	MLP	блок
Доля вычислений MLP	1.00	1.00	1.00	1.00	0.50	0.50	0.50	1.00	0.38	0.38	0.38
PPL WikiText-2 ↓	10.39	10.54	10.54	22.07	15.06	11.18	11.33	11.36	10.60	10.57	10.63
KL к исходной ↓	0.000	0.019	0.019	0.781	0.408	0.091	0.104	0.088	0.031	0.028	0.037
Совпадение top-1 ↑	100.0	94.3	94.4	62.5	73.9	88.8	87.5	87.9	93.5	94.0	92.4
LAMBADA ↑	64.0	63.5	64.0	36.0	51.0	60.5	61.0	60.5	64.5	64.0	65.5
HellaSwag ↑	57.0	59.5	59.5	55.0	55.5	58.0	57.5	57.5	56.5	59.5	60.0
ARC-e ↑	68.0	69.0	69.0	69.5	59.5	71.5	72.0	74.0	70.5	70.5	72.0
ARC-c ↑	43.5	43.5	43.5	43.0	38.0	47.0	46.5	45.5	46.0	43.5	44.5
PIQA ↑	77.5	79.0	79.0	75.5	69.5	72.5	72.0	75.5	73.0	77.0	76.0
WinoGrande ↑	61.5	61.0	61.0	56.0	55.5	62.5	63.0	60.0	65.0	64.0	65.0
MMLU (5-shot) ↑	64.6	65.6	67.7	37.2	45.6	58.9	58.2	64.9	63.5	66.3	64.2
Среднее по бенчам ↑	62.3	63.0	63.4	53.2	53.5	61.6	61.5	62.6	62.7	63.5	63.9

Таблица 3: Qwen3-1.7B-Base, те же столбцы, что в табл. 2.

робастный M-O4 стоит 4.7 % на WikiText-2 и 16.4 % на pile-10k, SVD-LLM — 12.8 и 36 % (рис. 6). Калибровка на pile-10k выравнивает ошибку (8.6 и 8.0 % у M-O4, 23 и 21.5 % у SVD-LLM), то есть смешанная калибровка — рабочее лекарство; текст, сгенерированный самой моделью, лекарством не является (16.3 и 11.6 %): сэмплы нерепрезентативны.

5.10 Второе семейство: SmolLM2-1.7B и Llama-3.2-1B

Таблицы 6 и 7 повторяют итоговую таблицу для двух моделей архитектуры Llama. Глубина k_{sink} определяется профилем автоматически: у Llama-3.2-1B массивная активация позиции 0 (норма 794 при медиане 2.4) появляется после слоя 1, как у Qwen3 — после слоя 2, поэтому $k_{\text{sink}} = 2$; у SmolLM2 сток позиции 0 (норма 26 235) возникает лишь после слоя 7, $k_{\text{sink}} = 8$. Три вывода. (1) Правило стока в исходном виде («позиция 0») для этого семейства неверно: окно 64 с одним стоком даёт $+64$ % PPL на SmolLM2 при $k = 8$ и $+13$ % на Llama-3.2-1B при $k = 2$, тогда как то же окно с правилом «сток — массивный ключ» (разд. 6.8) — 4.4 и 2.8 %, то есть столько же слоёв, сколько у Qwen3 при пороге 5 %. На кривой по k у SmolLM2 окно с позиционным стоком стоит 0.7, 2.1, 13.7, 27.3, 62.4 и 64.1 % при $k = 1, 2, 3, 4, 6, 8$; с массивными стоками — 0.8, 1.8, 2.0, 2.2, 3.5 и 4.4 % при тех же k, то есть та же форма кривой, что у Qwen3. (2) MLP первых слоёв у Llama-семейства заменяется заметно хуже,

Конфигурация	рост PPL, % [95% ДИ]	KL [95% ДИ]	среднее по бенчам ± 1.96 SE	источник
orig	0.0 [0.0; 0.0]	0.000 [0.000; 0.000]	54.5 ± 1.1	ci+bench1000
L1-window64	1.6 [1.5; 1.7]	0.015 [0.015; 0.015]	54.7 ± 1.1	ci+bench1000
MO4-routed25r	4.9 [4.6; 5.1]	0.059 [0.057; 0.061]	53.5 ± 1.1	ci+bench1000
ML5-svdllm50	13.2 [12.6; 13.8]	0.145 [0.140; 0.151]	52.5 ± 1.1	ci+bench1000
B-window+MO4-25r	5.4 [5.1; 5.7]	0.067 [0.065; 0.070]	53.5 ± 1.1	ci+bench1000

Таблица 4: Qwen3-0.6B, $k = 3$: рост PPL и KL на полном тесте WikiText-2 с 95 %-ми интервалами по бутстрэпу окон (283 окна по 1024 токена).

Контекст T	1024	2048	4096	8192
$k = 3$, 1 сток	1.81%	2.51%	3.21%	4.89%
$k = 3$, 4 стока	1.80%	2.48%	3.18%	4.49%
$k = 3$, 2 стока	1.81%	2.49%	—	—
$k = 3$, сток + переводы строки	1.80%	2.49%	—	—
$k = 6$, 2 стока	4.69%	6.27%	—	—
$k = 6$, сток + переводы строки	4.71%	6.28%	—	—

Таблица 5: Окно 64 в первых k слоях Qwen3-0.6B: рост PPL в зависимости от длины контекста и числа стоков (бюджет 65 тыс. токенов на длину).

чем у Qwen3: робастный M-O4 стоит 16 % на Llama-3.2-1B уже при $k = 2$ и 6.3 % на SmolLM2 при $k = 1$ (34 % при $k = 8$), SVD-LLM — 47 и 49 %, A3 — 97 и 499 %, позиционное внимание (relpos) и типизация голов O1 рушатся при $k \geq 2$. Диагностика обрыва показывает, что усиление ошибки по слоям $k - 1..k + 1$ у SmolLM2 равно 0.9–1.1, то есть обрыва нет: дорог сам первый MLP, а не его последствия для стока. Оракульный отбор 25 % нейронов одного слоя 0 даёт KL 0.0046 (меньше, чем у Qwen3-0.6B), так что узкое место — линейный предиктор нейронов при $I/d = 4$, а не отбор как таковой. (3) Робастная калибровка и защита нейронов стока нужны здесь ещё сильнее: наивная комбинация окно + M-O4 даёт +1 100 % на Llama-3.2-1B и +612 % на SmolLM2 ($k = 2$), робастная с защитой — 31.8 и 13.9 %; наивный M-O4 на SmolLM2 при $k = 2$ стоит 123 %, с защитой нейронов стока — 11.3 %. Бенчмарки в таблицах посчитаны на тех же подвыборках, что и для Qwen3.

5.11 Время

Наша ленточная реализация окна на чистом PyTorch, хотя и имеет асимптотику $O(Tw)$ и память $O(Tw)$, на MPS медленнее fused-ядра полного внимания в 5–40 раз на уровне слоя и замедляет prefill модели на 10–25 % (табл. 8). Реальное ускорение возможно только со специализированным ядром скользящего окна, которые существуют для CUDA; все оценки экономии в работе — по числу умножений.

6 Распространение ошибки и робастная калибровка

6.1 Аномалия: обрыв на $k = 3$

Кривые на рис. 3 для M-O4 и его комбинаций немонотонны: при $k = 2$ рост PPL составляет 3.0 %, при $k = 3$ — 27.0 %, а при $k = 4$ — снова 11.3 %. У окна, SVD-LLM и отбора нейронов по готовым активациям кривые гладкие. Поскольку $k = 3$ совпадает с k_{sink} (разд. 5), первая гипотеза естественна: слой 3, в котором впервые возникает сток внимания, усиливает ошибку, пришедшую из заменённых слоёв, а при $k = 4$ его собственная калибровка её компенсирует. Послойная диагностика (рис. 7) эту гипотезу опровергает и указывает на другой механизм.

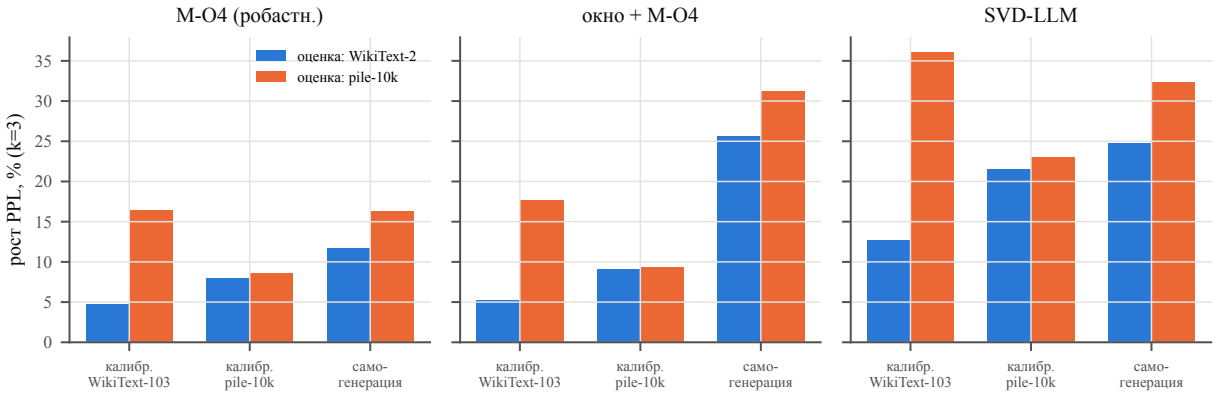


Рис. 6: Домен калибровки (Qwen3-0.6B, $k = 3$): рост PPL на WikiText-2 и на pile-10k при калибровке на WikiText-103, на pile-10k и на тексте, сгенерированном самой моделью.

	Исх.	Окно	Окно$_m$	Поз.	A3	SVD-LLM	Окно+SVD	O1	M-O4	M-O4г	Окно+M-O4г
Что заменено	—	вним.	вним.	вним.	блок	MLP	блок	вним.	MLP	MLP	блок
Доля вычислений MLP	1.00	1.00	1.00	—	0.50	—	—	—	0.35	0.35	0.35
PPL WikiText-2 ↓	8.93	14.65	9.32	—	53.47	—	—	—	12.00	12.00	17.74
KL к исходной ↓	0.000	0.503	0.044	—	1.795	—	—	—	0.314	0.313	0.713
Совпадение top-1 ↑	100.0	79.3	91.2	—	48.4	—	—	—	77.6	77.7	65.7
LAMBADA ↑	71.0	66.5	71.5	—	27.5	—	—	—	34.0	35.0	16.5
HellaSwag ↑	64.0	63.5	63.5	—	41.0	—	—	—	52.5	52.0	46.0
ARC-e ↑	75.0	75.5	75.5	—	32.5	—	—	—	57.5	56.0	43.0
ARC-c ↑	43.0	43.5	43.5	—	19.0	—	—	—	29.0	30.0	25.0
PIQA ↑	78.0	78.0	78.5	—	51.0	—	—	—	62.0	63.0	58.5
WinoGrande ↑	65.0	66.0	66.0	—	46.5	—	—	—	58.0	59.5	57.0
MMLU (5-shot) ↑	56.1	54.0	53.0	—	22.5	—	—	—	28.1	29.5	21.4
Среднее по бенчам ↑	64.6	63.9	64.5	—	34.3	—	—	—	45.9	46.4	38.2

Таблица 6: SmolLM2-1.7B, замена первых $k_{\text{sink}} = 8$ слоёв; столбцы как в табл. 2 (конфигурации, не поместившиеся в память ноутбука при $k = 8$, опущены). Окно с массивными стоками (L1-window64s) — правило разд. 6.8.

6.2 Послойная диагностика

Для каждой конфигурации мы сравниваем остаточный поток ученика и учителя на входе каждого слоя (относительная ошибка по токенам, без позиции 0). При $k = 2$ ошибка после заменённых слоёв равна 0.18–0.19 и далее монотонно убывает: каждый следующий слой гасит её с коэффициентом около 0.9. При $k = 3$ ошибка на входе слоя 3 равна 0.54, то есть скачок происходит *внутри заменённого слоя 2* (усиление 2.8), а слой 3 её не усиливает (коэффициент 0.86). Ошибка структурирована: 85 % её энергии приходится на 8 каналов массивной активации, тогда как у сигнала учителя в этих каналах 31 % энергии, у окна — 3.6 %, у SVD-LLM — 1.7 %. Это сдвигает масштаб токенов именно в тех координатах, по которым слой 3 отличает сток от остальных токенов: средняя масса внимания на позиции 0 падает с 0.63 до 0.50, а средняя абсолютная разность по позициям составляет 0.15. При $k = 4$ калибровка слоя 3 с компенсацией дрейфа снижает ошибку с 0.54 до 0.34, что и даёт «восстановление» на кривой.

6.3 Причина: одна строка калибровочной выборки

MLP слоя 2 — тот блок, который создаёт массивную активацию: норма остаточного потока на позиции 0 растёт с 19 до $\approx 7\,000$ именно на его выходе. Калибровочная выборка состоит из 256 окон по 512 токенов, вырезанных из текста без начального токена. В 1.6 % таких окон (33 из 2 048 в большом пуле) модель образует сток не на позиции 0, а на токене вроде «0», «8» или «=» на позиции 1–2: выход MLP слоя 2 для него имеет норму 6 400–7 100 при медиане 4.9. В первых 32 тыс. токенов нашей выборки такая строка одна и несёт 98.2 % энергии целей $\sum_t \|y_t\|^2$; во всей выборке их около

	Исх.	Окно	Окно$_m$	Поз.	A3	SVD-LLM	Окно+SVD	O1	M-O4	M-O4г	Окно+M-O4г
Что заменено	—	вним.	вним.	вним.	блок	MLP	блок	вним.	MLP	MLP	блок
Доля вычислений MLP	1.00	1.00	1.00	1.00	0.50	0.50	0.50	1.00	0.35	0.35	0.35
PPL WikiText-2 ↓	11.31	12.80	11.62	8803.33	22.23	16.58	20.87	14.75	13.14	13.14	14.90
KL к исходной ↓	0.000	0.113	0.030	6.630	0.665	0.384	0.602	0.258	0.151	0.152	0.280
Совпадение top-1 ↑	100.0	86.2	92.5	1.0	65.4	74.1	67.8	78.5	84.2	84.1	77.9
LAMBADA ↑	59.0	59.0	59.0	0.0	44.5	45.0	45.5	59.5	55.5	54.0	50.5
HellaSwag ↑	58.0	59.0	59.0	31.5	55.5	57.5	57.5	57.5	57.0	55.5	54.5
ARC-e ↑	60.5	61.0	61.0	26.0	50.0	52.5	53.0	61.0	58.5	58.0	55.5
ARC-c ↑	32.5	32.5	32.5	27.0	27.5	28.5	28.0	33.5	32.5	32.0	34.0
PIQA ↑	76.5	75.5	75.5	46.5	67.0	71.5	72.5	75.5	70.0	70.0	69.0
WinoGrande ↑	62.5	63.5	63.5	51.0	54.5	58.0	57.0	59.0	63.5	59.5	59.0
MMLU (5-shot) ↑	35.1	32.6	32.6	27.0	26.3	26.0	28.8	28.8	32.3	29.1	28.8
Среднее по бенчам ↑	54.9	54.7	54.7	29.9	46.5	48.4	48.9	53.5	52.8	51.2	50.2

Таблица 7: Llama-3.2-1B, замена первых $k_{\text{sink}} = 2$ слоёв; столбцы как в табл. 2.

Модель	T	слой внимания, мс		prefill модели, мс		отношение
		полное (SDPA)	лента (PyTorch)	исходная	первые 3 слоя — лента	
Qwen3-0.6B	1024	2.3	99.1	950	1275	0.74
Qwen3-0.6B	2048	8.5	209.3	2009	2657	0.76
Qwen3-0.6B	4096	37.6	457.7	4547	5695	0.80
Qwen3-0.6B	8192	163.2	894.5	11058	13331	0.83
Qwen3-1.7B	1024	2.2	96.9	2205	2557	0.86
Qwen3-1.7B	2048	7.6	193.6	4691	5287	0.89
Qwen3-1.7B	4096	29.7	386.7	9550	10696	0.89
Qwen3-1.7B	8192	155.7	808.6	21185	23572	0.90

Таблица 8: Замер времени на Apple M4 (MPS, bf16, медиана 5 запусков): ленточная реализация окна на чистом PyTorch против fused-ядра SDPA.

четырёх. Задача наименьших квадратов для линейной поправки и предиктора нейронов M-O4 подгоняется под эти строки, и ошибка в массивных каналах появляется у всех токенов. Слои 0 и 1 не затронуты, потому что до слоя 2 массивной активации ещё нет; в оценочных окнах таких токенов нет вовсе.

Ту же причину имеет неудача «корректоров»: поканальная, полная ($d \times d$), низкоранговая и ограниченная массивными каналами линейные карты на входе слоя 3, подогнанные по сырым остаткам, не уменьшают, а увеличивают рост PPL (с 27 до 35–45 %), поскольку те же строки доминируют и в регрессорах.

6.4 Формальная оценка: влияние одной строки

Все рассматриваемые калибровки сводятся к гребневой регрессии $W = (\Phi^\top \Phi + \lambda I)^{-1} \Phi^\top Y$ по строкам (φ_t, y_t), где φ_t — признаки токена t (вход блока с единицей для смещения), y_t — цель. Пусть строка o добавлена к набору S остальных строк, $A = \Phi_S^\top \Phi_S + \lambda I$, $W_S = A^{-1} \Phi_S^\top Y_S$ — решение без неё, $r_o = y_o - \varphi_o^\top W_S$ — её невязка относительно этого решения и $h_o = \varphi_o^\top A^{-1} \varphi_o$ — её рычаг.

Предложение 1. *Решение с добавленной строкой равно* $W_{S \cup o} = W_S + \dfrac{A^{-1} \varphi_o \, r_o^\top}{1 + h_o}$, *и для любого токена* t *изменение предсказания равно*

$$\Delta \hat{y}_t = \frac{c_t}{1 + h_o} \, r_o, \qquad c_t = \varphi_t^\top A^{-1} \varphi_o,$$

так что $\|\Delta \hat{y}_t\| \le \dfrac{|c_t|}{1 + h_o} \, \|r_o\|$, *причём* $\Delta \hat{y}_t$ *направлено вдоль* r_o *для всех* t *одновременно.*

Доказательство. По формуле Шермана—Моррисона $(A + \varphi_o \varphi_o^\top)^{-1} = A^{-1} - \frac{A^{-1} \varphi_o \varphi_o^\top A^{-1}}{1 + h_o}$. Подставляя в $W_{S \cup o} = (A + \varphi_o \varphi_o^\top)^{-1} (\Phi_S^\top Y_S + \varphi_o y_o^\top)$ и группируя слагаемые, получаем $W_{S \cup o} - W_S = \frac{A^{-1} \varphi_o}{1 + h_o} \, (y_o - \varphi_o^\top W_S)^\top$; умножение слева на $\varphi_t^\top$ даёт утверждение. □

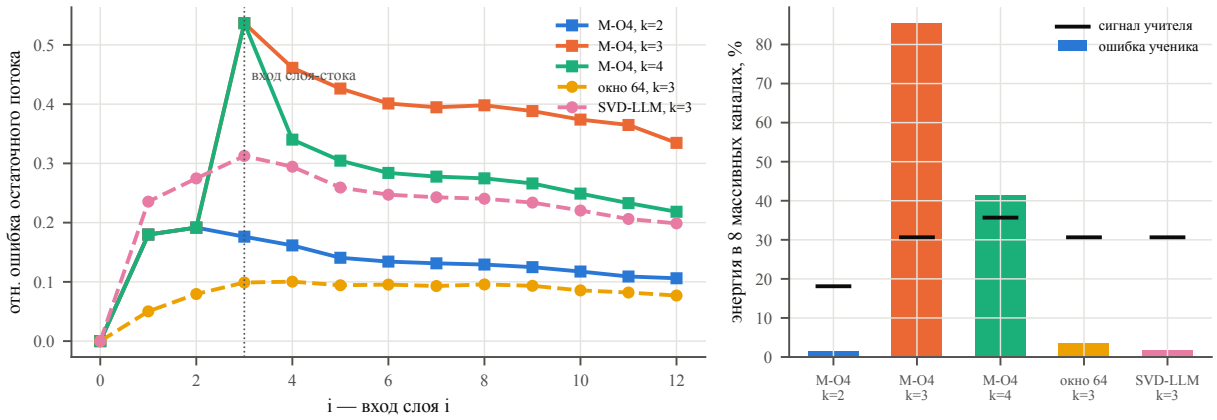


Рис. 7: Диагностика обрыва (Qwen3-0.6B, 8 окон по 1024 токена, позиции ≥ 1). Слева — относительная ошибка остаточного потока ученика на входе каждого слоя. Справа — доля энергии ошибки на входе первого незаменённого слоя, приходящаяся на 8 каналов массивной активации (чёрточка — доля энергии сигнала учителя в тех же каналах).

Модель, слой 2	доля энергии o	h_o	$\|r_o\|$	$\overline{\|c_t\|}$	утечка (медиана / p90)	ошибка формулы
Qwen3-0.6B	26 %	0.094	5 250	$5.6 \cdot 10^{-4}$	53 % / 112 %	$4 \cdot 10^{-5}$
Qwen3-1.7B	27 %	0.128	9 801	$6.2 \cdot 10^{-4}$	47 % / 100 %	$4 \cdot 10^{-5}$

Таблица 9: Влияние строки с максимальной нормой цели в калибровке (131 тыс. токенов) на гребневую регрессию для MLP слоя 2: доля энергии целей, рычаг, невязка, средняя связь с обычными токенами, предсказанная относительная утечка в их предсказания и относительная ошибка формулы Шермана—Моррисона. Для слоёв 0, 1 и 3 утечка не превышает 0.5 %.

Предложение объясняет два наблюдения и опровергает третье. Во-первых, ошибка от строки с массивной активацией у *всех* токенов лежит в одном направлении r_o — в каналах массивной активации (85 % энергии ошибки на рис. 7). Во-вторых, её величина пропорциональна $\|r_o\|$ и связи c_t. Измерения на слое 2 (табл. 9) подтверждают формулу: отклонение $W_{S\cup o} - W_S$ от предсказания Шермана—Моррисона составляет $4 \cdot 10^{-5}$, а предсказанная утечка в обычные токены — около половины нормы их целей (медиана 53 % на 0.6B и 47 % на 1.7B). Третье наблюдение — отсутствие обрыва на Qwen3-1.7B при том же выбросе (норма 14 355) — предложение *не* объясняет: утечка там такая же. Разница в следующем слое: на 0.6B возмущение массивных каналов снижает массу стока в слое 3 с 0.63 до 0.50, на 1.7B она не меняется (0.589 против 0.586), и дальнейшие слои гасят ошибку. Иммунитет большей модели — свойство устойчивости её стока, а не регрессии. Величины h_o, $\|r_o\|$ и $\overline{|c_t|}$ измеримы *до* построения замены и дают априорный критерий опасности калибровочной выборки.

6.5 Управляемый эксперимент

Если причина — состав калибровки, обрыв должен включаться и выключаться числом отравленных окон. Мы просканировали пул из 2 048 окон, пометили окна с массивной активацией на позиции ≥ 1 и собирали калибровку из 256 окон с $n = 0, 1, 4, 16$ отравленными (рис. 8). На Qwen3-0.6B наивный M-O4 при $k = 3$ даёт 4.2 % при $n = 0$ и $n = 1$, 23.9 % при $n = 4$ и 379 % при $n = 16$; робастная калибровка при $n = 16$ возвращает 4.1 %. На Qwen3-1.7B все дозы дают 1.6–1.7 %. Зависимость от дозы причинная, порог — между одним и четырьмя окнами из 256, и стандартная выборка с ≈ 4 отравленными окнами попадает ровно в область обрыва.

6.6 Нейроны стока

Массивную активацию позиции 0 создают единичные нейроны MLP слоя 2: на Qwen3-0.6B пять нейронов дают 90 % вклада, на Qwen3-1.7B — один нейрон 94 % (табл. 10). Их удаление во всех по-

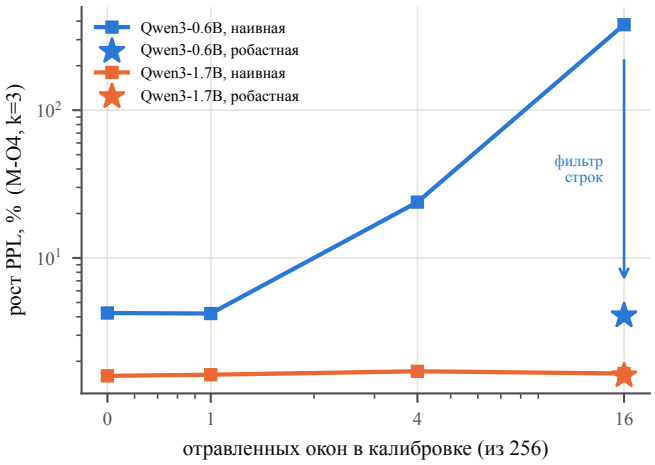


Рис. 8: Рост PPL наивно откалиброванного M-O4 ($k = 3$) в зависимости от числа отравленных окон в калибровочной выборке из 256 окон; звёздочки — робастная калибровка при $n = 16$.

Модель	слой	нейронов	доля вклада в поз. 0	удалить везде		удалить при $t \geq 1$	случайные
				ΔPPL	$\|h_0\|$ после слоя	ΔPPL	ΔPPL
Qwen3-0.6B	2	5	90%	+54.4%	429	+0.3%	-0.0%
Qwen3-1.7B	2	1	94%	+230.9%	225	+0.0%	-0.0%

Таблица 10: Нейроны стока в слое $k_{\text{sink}} - 1$ и абляции (8 окон по 1024 токена): удаление во всех позициях, только при $t \geq 1$ (позиция 0 точно) и такого же числа случайных нейронов.

зициях уничтожает сток (норма h_0 падает с 6 897 до 429 и с 14 701 до 225) и разрушает модель: $+54\,\%$ и $+231\,\%$ PPL. Удаление тех же нейронов только на позициях $t \geq 1$ стоит $0.3\,\%$ и $0.0\,\%$, случайных нейронов — ничего. Это объясняет, почему любой отбор нейронов в ранних слоях обязан либо считать позицию 0 точно (как все наши MLP-замены), либо защищать эти нейроны явно: в робастной статистике, исключающей позицию 0 и выбросы, нейрон стока невидим — вся его энергия сосредоточена именно там. Полный A3 без точной позиции 0 с робастным отбором терял его и давал $+556\,\%$ на 1.7B; с точной позицией 0 — $46\,\%$, как и наивный. Нейроны стока — MLP-аналог «супервесов» [34]: несколько параметров, без которых модель не работает.

6.7 Робастная калибровка

Исправление детерминировано и бесплатно: из всех сумм по токенам исключаются строки с $\|y_t\| > \tau\,\text{med}_t\,\|y_t\|$, $\tau = 10$ (правило не задевает ни одной обычной строки: доля токенов с $\|z\| > 10\,\text{med}$ сверх выбросов равна нулю на обеих моделях), а в критериях отбора нейронов — ещё и позиция 0 при точном её вычислении. С робастной калибровкой обрыв исчезает (рис. 3): рост PPL у M-O4 при $k = 3$ составляет $4.7\,\%$ вместо $27.0\,\%$, при $k = 4$ — 6.4 вместо 11.3, при $k = 6$ — 8.7 вместо 13.0, при $k = 8$ — 11.0 вместо 14.9, при $k = 12$ — 14.7 вместо 19.3; у комбинации окно + M-O4 — 5.2, 7.5, 10.1, 13.6 и $22.2\,\%$ вместо 29.6, 13.1, 14.9, 18.1 и 27.6. Выигрыш виден и на бенчмарках при $k = 3$: средняя точность по семи задачам у M-O4 растёт с 44.4 до $54.6\,\%$ при $54.9\,\%$ у исходной модели, у окна + M-O4 — с 46.2 до $54.3\,\%$. Та же поправка спасает M-O1 с $25\,\%$ точных нейронов ($54.2 \to 10.2\,\%$) и табличную замену M-O2 ($30.6 \to 12.2\,\%$). Робастная замкнутая форма оказывается сильнее наивной калибровки с последующей дистилляцией: 300 шагов AdamW снижают ошибку M-O1 лишь до $12.5\,\%$.

Кого ловушка не касается. Табл. 11 сравнивает наивную и робастную калибровку для всех методов. Опубликованные методы не страдают: SVD-LLM (12.8 против $12.6\,\%$), ASVD (38.5 против $38.7\,\%$) и A3 (9.9 против $9.9\,\%$) используют статистики для *ранжирования* или *отбеливания*, а не как

Метод	наивная калибровка		робастная	
	ΔPPL	KL	ΔPPL	KL
SVD-LLM 50%	12.8%	0.138	12.6%	0.137
ASVD 50%	38.5%	0.359	38.7%	0.361
A3 FFN 50%	9.9%	0.114	9.9%	0.113
A3 (блок)	49.2%	0.433	49.5%	0.435
M-O2: таблица по токену	30.6%	0.288	12.2%	0.141
M-O1: линейный + 25%	57.7%	0.480	10.2%	0.115
M-O4: предиктор 25%	27.0%	0.268	4.7%	0.056
Окно + M-O4	29.6%	0.286	5.2%	0.065

Таблица 11: Наивная и робастная калибровка при $k = k_{\text{sink}}$ (Qwen3-0.6B, WikiText-2, 32 окна). Методы ранжирования и отбеливания (SVD-LLM, ASVD, A3) не меняются; регрессионные замены меняются в разы.

цели регрессии. Так, в матрице $X^\top X$ входов down-проекции слоя 2, которую отбеливает SVD-LLM, позиция 0 даёт $98.4\,\%$ следа, а среди позиций ≥ 1 один токен — $25.6\,\%$; но доминирующее направление лишь получает собственную сингулярную компоненту и сохраняется при усечении. Страдают методы, решающие задачу наименьших квадратов с целями в остаточном потоке: наши M-O1, M-O2, M-O4 и, как показано ниже, корректоры на границе блоков. Проверка на родных настройках SVD-LLM и ASVD (сжатие 10 и 20 %, калибровка 256 окон по 2048 токенов, $k = 3$) подтверждает это: наивная и робастная статистики дают одинаковый результат (SVD-LLM 4.7/4.7 и 3.2/3.3 % на 0.6B, 1.5/1.5 и 0.9/0.9 % на 1.7B; ASVD 9.5/9.5 и 5.5/5.5, 4.9/4.9 и 3.0/3.0 %). Заметим, что при 20 % сжатия SVD-LLM стоит столько же, сколько M-O4 при 75 % экономии MLP.

Корректор на границе. Оператор выравнивания активаций на границе заменённого блока (ReplaceMe [32], Ghosted Layers [33]) — та же регрессия. Подогнанный наивно, он ухудшал наивный M-O4 (разд. выше); подогнанный с исключением строк-выбросов, он исправляет его: $27.0 \to 4.8\,\%$ для полной карты $d \times d$ и 4.7 % для карты, корректирующей только 8 каналов массивной активации. На робастно откалиброванном M-O4 корректор ничего не добавляет ($4.7 \to 4.7\,\%$). Восьми каналов достаточно — прямое подтверждение того, что вся ошибка ловушки лежит в направлении r_o.

6.8 Стоки на токенах: второе семейство

У моделей архитектуры Llama правило «сток — позиция 0» оказывается частным случаем более общего. На SmolLM2-1.7B массивную активацию (норма $\approx 2\,900$ при медиане 33 после слоя 1) создаёт один нейрон MLP слоя 1 (№ 4987, 68–89 % вклада) на токене « the » (а также на первых кавычке и двойном переводе строки) в *любой* позиции; сток позиции 0 появляется лишь после слоя 7, и до него поздние слои используют как стоки именно эти массивные токены. На Llama-3.2-1B массивную активацию позиции 0 создают 12 нейронов MLP слоя 1 (90 % вклада); их удаление во всех позициях стоит $+1\,353\,\%$ PPL, только при $t \geq 1$ — 0.9 %, у SmolLM2 64 нейрона слоя 7 (86 %) — $+2\,190$ и $0.2\,\%$. Механизм тот же, что у Qwen3, но триггер иной.

Следствий два, и оба меняют замены. Во-первых, калиброванные замены MLP без защиты рушатся даже с робастным фильтром строк по норме входа, потому что массивные строки сидят в *целях* регрессии на обычных токенах: на SmolLM2 при $k = 2$ M-O4 даёт $+123\,\%$, окно + M-O4 — $+612\,\%$. Лечение детерминировано: нейроны стока находятся по калибровке априори (токены с $\|\text{MLP}(x)\| > 20$ med, нейроны, покрывающие 90 % их вклада), всегда остаются в маске предиктора и отборе, у SVD выносятся из факторизации и добавляются точно, а строки с большой невязкой регрессии исключаются из подгонки (невязка нужна потому, что окно внимания меняет набор токенов, становящихся массивными). После этого M-O4 стоит $11.3\,\%$, окно + M-O4 — $13.9\,\%$, гребневая замена — $15.3\,\%$; SVD-LLM остаётся непригодным (123 %). На Qwen3 те же правки не меняют ни одного числа (4.7, 12.7 и 5.2 % при $k = 3$ на 0.6B), потому что там нейроны стока действуют только в позиции 0, которая

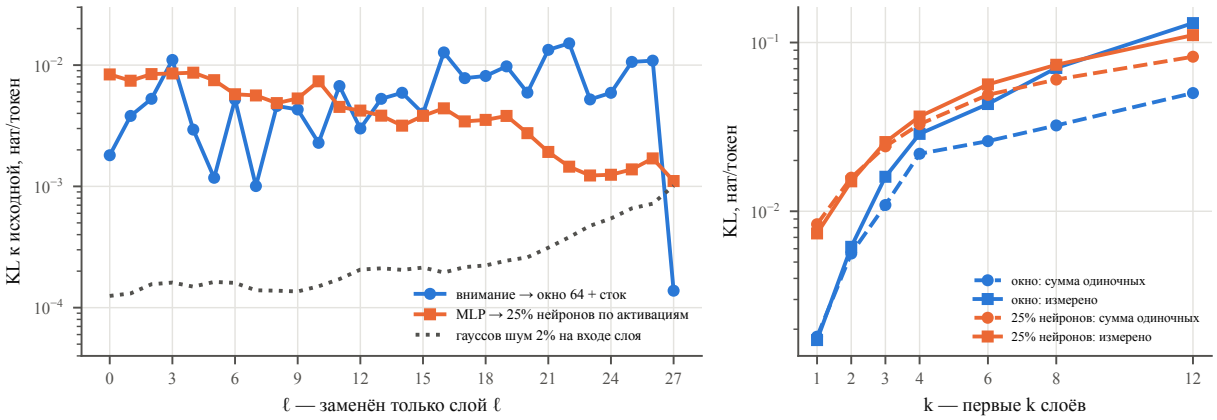


Рис. 9: Слева — карта заменяемости Qwen3-0.6B: KL при замене только слоя ℓ (внимание — окно 64 + сток; MLP — 25 % нейронов) и при изотропном шуме 2 % на его входе. Справа — аддитивность: сумма KL одиночных замен первых k слоёв против измеренного KL при их одновременной замене.

и так считается точно. Во-вторых, окно внимания должно хранить массивные ключи в любой позиции: ключ считается стоком, если отношение пика его каналов к среднему после RMSNorm превышает удвоенную медиану по последовательности (априорное правило без калибровки). На SmolLM2 это даёт 2.0 % вместо 13.7 % при $k = 3$, 3.5 вместо 62.4 % при $k = 6$ и 4.4 вместо 64.1 % при $k = 8$ ценой 0.2–4.4 % лишних ключей; на Llama-3.2-1B — 2.8 вместо 13.1 % при $k = 2$; на Qwen3 ничего не портит: на 1.7B при $k = 1..8$ кривая совпадает с позиционным стоком или чуть ниже (5.5 вместо 5.7 % при $k = 8$) при 0–0.1 % лишних ключей. Дозовый эксперимент на этом семействе ловушку не включает (33.2–33.6 % при 0–16 отравленных окнах на SmolLM2, 15.6–15.8 % на Llama-3.2-1B): отравление здесь не в составе калибровки, а в самих данных, где массивные токены есть всегда.

6.9 Вывод

Любая калибровка в замкнутой форме, которая накапливает суммы по токенам — гребневая регрессия, отбор нейронов по $\sum_t z_t^2$, PCA входов — должна исключать позицию 0 и токены с массивной активацией. Иначе ошибка приближения ложится в каналы стока и разрушает механизм внимания ниже по потоку, причём ровно на том слое, где появляется сток. Для квантования аналогичная роль каналов-выбросов известна [26]; здесь показано, что при структурной замене блоков опасен не канал, а единичный токен в данных. В общем виде правило звучит так: сток — это массивная активация, где бы она ни возникла; позиция 0 у Qwen3 — частный случай, токен «the» у SmolLM2 — другой, и замена обязана сохранять и нейроны, создающие такие активации, и ключи, которые их несут.

7 Карта заменяемости и априорный критерий

Кривые «первые k слоёв» отвечают на вопрос о префиксе модели, но не говорят, какие слои заменяемы вообще и можно ли это предсказать без запуска замены. Для этого мы заменяем *по одному* слою $\ell = 0, \ldots, 27$ при неизменных остальных: внимание — окном 64 со стоком, MLP — отбором 25 % нейронов по готовым активациям; для сравнения на вход слоя ℓ подаётся гауссово возмущение с относительной нормой 2 %. Качество — KL к исходной модели на 8 окнах по 1024 токена. Параллельно на состояниях учителя считаются статистики, не требующие замены: масса внимания вне окна (без стока), локальная ошибка окна на выходе блока внимания, доля вклада 25 % сильнейших нейронов в выход MLP и локальная ошибка их отбора.

Карта по глубине. Для внимания KL одиночной замены меняется на два порядка по глубине и немонотонно: легче всего заменяются слои 27, 7, 5, 0, 10 и 4 (KL ≤ 0.003), труднее всего — 22, 21 и 16

Блок	Статистика (без запуска замены)	Спирмен с KL
Внимание	масса внимания вне окна	0.37
	локальная ошибка окна (отн. выхода внимания)	0.82
	ошибка относительно остаточного потока	0.52
	то же $\times$ чувствительность слоя	0.77
MLP	$1-$ доля вклада 25% сильнейших нейронов	0.92
	локальная ошибка отбора (отн. выхода MLP)	0.82
	ошибка относительно остаточного потока	0.97
	то же $\times$ чувствительность слоя	0.96

Таблица 12: Ранговая корреляция Спирмена (28 слоёв) между статистиками слоя, вычисленными без замены, и KL при его одиночной замене.

(≥ 0.013); слой-сток 3 оказывается одним из трудных (0.011), так как помимо стока содержит головы с дальним контекстом. Для MLP картина противоположна исходной посылке о «простых первых слоях»: KL максимален в слоях 0–4 (0.0084–0.0087) и минимален в слоях 21–27 (0.0011–0.0019). Иными словами, MLP первых слоёв — самые *незаменяемые* отбором нейронов во всей модели, а поздних — самые заменяемые; это согласуется с ростом разреженности активаций по глубине и с ролью ранних MLP как «детокенизатора» [1].

Априорный критерий. Для MLP достаточно одной статистики: доля вклада 25 % сильнейших нейронов предсказывает KL одиночной замены с корреляцией 0.92, а локальная ошибка отбора, отнесённая к норме остаточного потока, — 0.97 (табл. 12). Для внимания масса вне окна предсказывает плохо (0.37): важно не то, сколько массы теряется, а как меняется выход блока; локальная ошибка окна даёт 0.82.

Воспроизводимость на 1.7B. Все три наблюдения повторяются на Qwen3-1.7B без подгонки: корреляции Спирмена составляют 0.91–0.96 для MLP и 0.33–0.77 для внимания; карта по глубине почти та же (внимание легче всего заменяется в слоях 27, 5, 7, 10, 0, труднее всего — в 21, 22 и слое-стоке 3; MLP слоёв 21–27 заменяется в 15–20 раз легче, чем слоёв 3–5); сумма одиночных KL совпадает с измеренной для отбора нейронов (0.043 против 0.050 при $k = 8$) и занижает её для окна (0.035 против 0.066).

Аддитивность и направление ошибки. Для отбора нейронов сумма KL одиночных замен первых k слоёв почти совпадает с измеренным KL при их совместной замене (0.024 против 0.026 при $k = 3$, 0.082 против 0.111 при $k = 12$). Для окна сумма занижает: 0.011 против 0.016 при $k = 3$ и 0.050 против 0.130 при $k = 12$, то есть ошибки окна взаимодействуют и накапливаются супераддитивно. Та же разница видна по отношению KL к энергии возмущения: ошибка окна вредит в 2–6 раз сильнее изотропного шума той же энергии на том же слое, а ошибка отбора нейронов ведёт себя как шум (отношение 0.9–1.6). Прямое измерение структуры ошибок подтверждает это: ковариация ошибки на выходе модели при замене окном имеет эффективный ранг 19–115 (на 8 главных компонент приходится 20–44 % энергии), при отборе нейронов — 83–277 (11–23 %); средний косинус между ошибками от замен разных слоёв равен 0.071 для окна против 0.022 для MLP (0.135 против 0.034 среди первых шести слоёв). Ошибки окна низкоранговы и согласованы между слоями — они складываются; ошибки отбора нейронов близки к изотропному шуму и складываются по энергии.

CATS не работает в ранних слоях. Пороговый отбор по величине $|\mathrm{act}(\mathrm{gate})|$ [30], который в литературе применяют ко всей модели, в одиночной замене слоя проигрывает отбору по полному вкладу нейрона в 5–37 раз в слоях 0–5 и лишь в 1.3–3 раза в слоях 22–27 (рис. 10); на 1.7B — в 2.5–5.6 и 1.3–3 раза. При замене первых трёх слоёв CATS с 25 % активных нейронов даёт $+70$ % PPL, при $k = 4$ — почти $+300$ %. В ранних слоях важен критерий отбора, и именно там дешёвые пороговые методы не применимы.

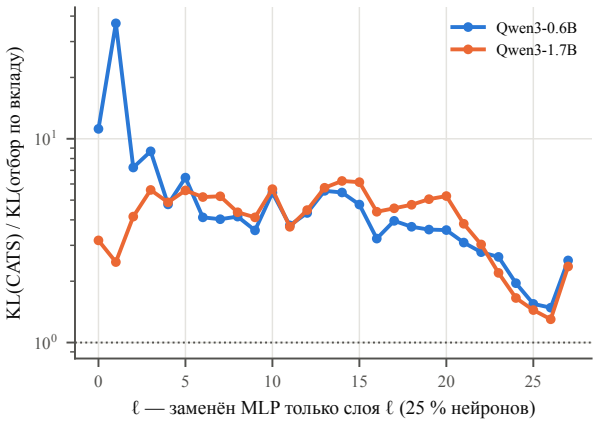


Рис. 10: Отношение KL при пороговом отборе CATS к KL при отборе 25 % нейронов по вкладу, замена MLP одного слоя ℓ.

Почему MLP ранних слоёв незаменим. Карта фиксирует факт, а не причину. Мы сопоставили KL одиночной замены MLP с пятью свойствами слоя, измеренными на состояниях учителя (Qwen3-0.6B). Сильнее всего с KL связана концентрация вклада (доля 25 % сильнейших нейронов, Спирмен -0.92) и число существенно активных нейронов (вклад выше 1 % от максимального по токену, Спирмен $+0.70$): в слоях 0–5 активны 1 900–2 300 нейронов из 3 072, в слоях 21–26 — 1 200–1 400, в слое 27 — 275. Второй фактор — величина записи: норма выхода MLP относительно остаточного потока равна 0.45–0.72 в слоях 0–4 и 0.22–0.40 в слоях 11–26 (Спирмен $+0.44$); эффективный ранг выхода ведёт себя так же ($+0.52$). Гипотеза о том, что ранние MLP пишут именно в подпространство, которое читают ключи и запросы слоя-стока, не подтвердилась: доля их выхода в этом подпространстве (0.74) совпадает со случайным подпространством той же размерности (0.78). Наконец, ошибка отбора на продолжениях слов выше, чем на началах, только в слоях 0–5 (0.18–0.22 против 0.14–0.19), а с седьмого слоя разницы нет. Итог: MLP ранних слоёв пишет в остаточный поток большие, плотные и высокоранговые векторы — в особенности когда собирает слово из нескольких токенов, — и любое подмножество нейронов теряет заметную долю такого вектора; MLP поздних слоёв разрежен и мал относительно уже большого остаточного потока, поэтому его легко заменить. [TODO: добавить 1.7B и SmolLM2 после прогона]

Что не покрывается словарём. Разбиение ошибки остаточного потока на входе слоя 3 по типам токенов показывает, чего не хватает каждой замене. Табличная замена MLP по токену (M-O2, робастная; средняя относительная ошибка 0.31) хуже всего на продолжениях слов (0.59 против 0.25–0.30 для пунктуации, начал слов и цифр), и десять худших токенов — это фрагменты вроде «se», «ga», «ter», «ly»: сборка слова из кусков требует контекста соседей, которого у таблицы нет. У предиктора нейронов M-O4 (0.21) тот же профиль в смягчённом виде (0.41 на продолжениях). Окно (0.11), напротив, одинаково хорошо справляется с началами и продолжениями слов (0.09–0.10), а хуже всего — на переводах строки и разделителях (0.17–0.27): редкие структурные токены, которым нужен далёкий контекст. Иными словами, первые слои делают две разные вещи: локальную сборку слов из кусков, которую окно сохраняет, а словарь теряет, и разметку структуры документа, для которой нужен хвост контекста.

7.1 Планировщик замен по априорным статистикам

Критерий позволяет выбирать, *что* заменять, не запуская замены. Мы подгоняем на Qwen3-0.6B две лог-линейные зависимости KL одиночной замены от статистик (локальная ошибка окна для внимания; ошибка отбора относительно остаточного потока для MLP) и показатель супераддитивности внимания $\gamma = 0.47$ по кривой howmany, затем применяем их к Qwen3-1.7B *по её собственным статистикам*: предсказанные KL одиночных замен коррелируют с измеренными на уровне 0.75 (внима-

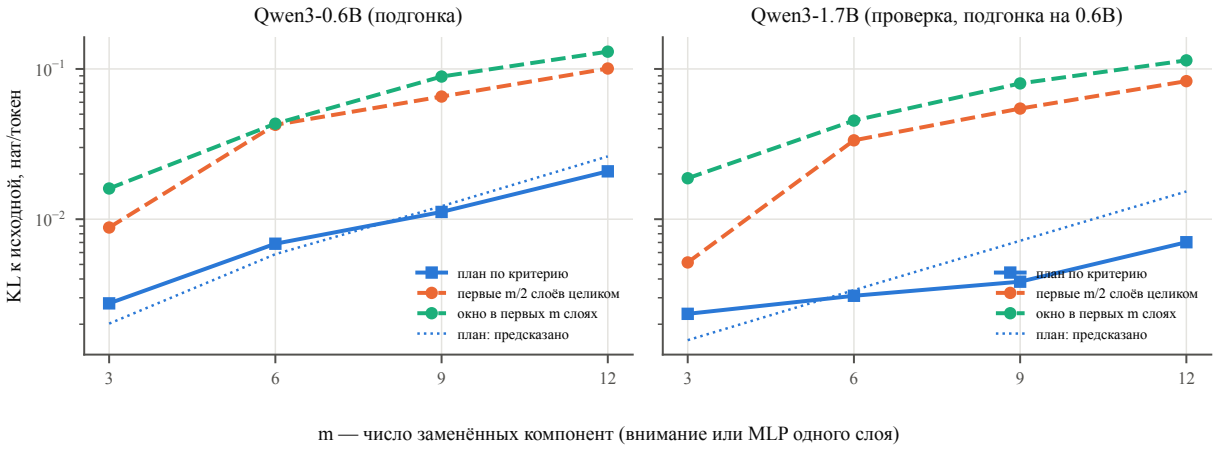


Рис. 11: Планировщик по априорным статистикам против замены префикса: KL в зависимости от числа заменённых компонент m. Зависимости подогнаны на Qwen3-0.6B (слева) и без изменений применены к Qwen3-1.7B (справа); пунктир — предсказание плана.

ние) и 0.94 (MLP). Жадный план из m компонент с минимальным предсказанным итогом сравнивается с двумя префиксами: первые $m/2$ слоёв целиком и окно в первых m слоях (рис. 11). При $m = 6$ план даёт KL 0.0031 (+0.1 % PPL) против 0.0335 (+3.2 %) и 0.0453 (+4.0 %); при $m = 12$ — 0.0070 (+0.4 %) против 0.083 и 0.114. План состоит из MLP поздних слоёв (23–27) и внимания слоя 0, то есть критерий сам уводит замену от префикса в хвост модели. На 0.6B (подгонка и проверка на одной модели) выигрыш тот же: при $m = 12$ — 2.2 % против 9.5 и 13.9 %.

Второе семейство. Те же зависимости, подогнанные на Qwen3-0.6B, применены без изменений к SmolLM2-1.7B и Llama-3.2-1B по их собственным статистикам. Планировщик переносится: на SmolLM2 при $m = 6$ план даёт KL 0.026 (+2.6 % PPL) против 0.145 (+15.8 %) у префикса из трёх блоков и 0.49 (+62 %) у окна в шести первых слоях (с позиционным стоком); план состоит из внимания слоёв 0, 22, 23 и MLP слоёв 20–22, то есть снова уходит из начала модели. На Llama-3.2-1B при $m = 6$ — 7.9 % против 20.7 и 22.3 %, при $m = 12$ — 28.1 против 35.7 и 47.2 %; при $m = 3$ префикс из блока 0 целиком (3.2 %) лучше плана (4.6 %): у 16-слойной модели предсказание KL внимания завышено. Критерий для MLP переносится хуже: ранговая корреляция концентрации вклада с KL замены составляет -0.25 на SmolLM2 и -0.51 на Llama-3.2-1B против -0.91 на Qwen3-1.7B, а поздние MLP у SmolLM2 не дешевле ранних (KL одиночной замены 0.004–0.0075 по всей глубине, слой 23 — самый дорогой), тогда как у Qwen3 они в 5–30 раз дешевле. Сравнение CATS с отбором по вкладу (отношение ошибок 1.8–3.7 по всем 24 слоям) и аддитивность воспроизводятся.

8 Обсуждение и ограничения

Связь с дискуссией о «чистоте» сетей. Замена слоя явным алгоритмом с малым KL — конструктивная форма утверждения «мы понимаем, что делает этот слой» в смысле критерия Gao [7]. По этому критерию первые слои Qwen3 «чисты» наполовину: их внимание действительно локально и сводится к окну с потерей 1.5–1.8 % PPL, а их MLP — нет: лучшая явная замена с предсказанием нейронов стоит 4.7 % на 0.6B и 1.7 % на 1.7B, табличная замена по токену — 12 %, линейная — 20 %. При этом MLP поздних слоёв по карте заменяемости в 15–20 раз «чище» ранних. Иными словами, простота первых слоёв — свойство их внимания, а не их MLP.

Четыре практических правила. Из результатов следуют правила для любой пост-хок замены блоков в замкнутой форме: (1) суммы по токенам не должны включать строки с массивной активацией — одна такая строка в калибровке доминирует в задаче наименьших квадратов, а порог опасности ле-

жит между одним и четырьмя окнами из 256; (2) сток — это массивная активация, где бы она ни возникла: нейроны, создающие её, должны сохраняться явно, а окно внимания — хранить несущие её ключи; у Qwen3 это позиция 0, у Llama-семейства — ещё и токены вроде «the» в любой позиции, и без этого правила окно стоит 64 % вместо 4 % на SmolLM2; (3) выбирать блок для замены надо по измеренной чувствительности, а не по косинусной близости состояний: на Qwen3-0.6B косинусный критерий ошибается в 4–5 раз; (4) калибровать надо на смеси доменов — иначе ошибка калиброванной замены вне домена втрое выше.

Ограничения.

- Ускорение оценивается по числу операций. Измеренное время (табл. 8) показывает, что без специализированного ядра окна реализация на чистом PyTorch медленнее fused-ядра полного внимания; экономия в несколько процентов умножений на первых слоях сама по себе ускорения не даёт, выигрыш окна — память кэша ключей-значений на длинном контексте.
- Калибровка на одном домене переобучает калиброванные замены MLP (ошибка вне домена втрое выше); смешанная калибровка выравнивает ошибку ценой роста внутри домена.
- Исследованы два семейства (Qwen3-0.6B/1.7B, SmolLM2-1.7B, Llama-3.2-1B) размером до 1.7B; вычисления выполнены на ноутбуке. Выводы о внимании и о стоках повторяются на обоих семействах, выводы о заменимости MLP и об априорном критерии для MLP — нет: у Llama-семейства первый MLP дороже, а концентрация вклада предсказывает KL слабее. Вопрос о сохранении «обменного курса» с ростом размера требует моделей 4B–32B. Кривые по k для Llama-3.2-1B и точки окна с массивными стоками при всех k досчитываются; в таблицах они отмечены.
- Бенчмарки посчитаны на подвыборках: по 200 примеров для всех столбцов (± 2.5 п.п. для среднего по семи задачам) и по 1000 для главных (± 1.1 п.п.); интервалы для PPL и KL даны по бутстрэпу окон.
- Дистилляционный контроль (300 шагов AdamW) ограничен шестью методами и малым числом шагов; для метода O4 он расходится.
- Методы из литературы адаптированы к Qwen3 (A3) или взяты в детерминированной части (SVD-LLM без дообучения, Deja Vu в оракульном режиме, MoEfication без обучаемого маршрутизатора). Их обучаемые варианты оценены только в дистилляционном контроле.

9 Заключение

Мы спросили, можно ли заменить первые слои готовой LLM явными детерминированными алгоритмами, и получили ответ в четырёх частях. Внимание первых слоёв — да: окно из 64 позиций со стоком заменяет первые три слоя Qwen3-0.6B и 1.7B с ростом PPL 1.5–1.8 % и без изменения точности на бенчмарках, первые шесть — в пределах 5 %, и число стоков, как и длина контекста до 8 тыс. токенов, на это почти не влияют. MLP первых слоёв — лишь частично: предсказание 25 % активных нейронов в замкнутой форме (M-O4) стоит 4.7 и 1.7 % PPL при стоимости 0.3 MLP, тогда как пороговый отбор, линейные карты и низкоранговые приближения теряют в разы больше, а по карте заменяемости MLP ранних слоёв — самые незаменимые во всей модели. Любая калибровка в замкнутой форме — только с защитой от массивных активаций: одна строка данных отравляет регрессию (что мы доказали формулой, воспроизвели дозой и вылечили исключением строк), а один нейрон, создающий сток, должен быть сохранён. Второе семейство показало общий вид этого правила: сток — массивная активация, у SmolLM2 её создаёт один нейрон на токене «the» в любой позиции, и только защита таких нейронов и хранение таких ключей делают замены переносимыми (окно: 64 $\rightarrow$ 4 %; M-O4: 123 $\rightarrow$ 11 %). Наконец, дешёвые априорные статистики предсказывают заменяемость слоёв и

на непросмотренной модели выбирают план замен в 10–15 раз лучше префикса. Все замены укладываются в один обменный курс — около процента PPL за процент вычислений на 0.6B и вдвое лучше на 1.7B, — и проверка того, продолжает ли курс улучшаться с размером, составляет следующий шаг.

Список литературы

[1] N. Elhage et al. A Mathematical Framework for Transformer Circuits. Transformer Circuits Thread, 2021. https://transformer-circuits.pub/2021/framework/index.html

[2] A. Vaswani et al. Attention Is All You Need. NeurIPS, 2017. arXiv:1706.03762.

[3] M. Geva et al. Transformer Feed-Forward Layers Are Key-Value Memories. EMNLP, 2021. arXiv:2012.14913.

[4] J.-B. Cordonnier et al. On the Relationship between Self-Attention and Convolutional Layers. ICLR, 2020. arXiv:1911.03584.

[5] Y. Dong et al. Attention is Not All You Need: Pure Attention Loses Rank Doubly Exponentially with Depth. ICML, 2021. arXiv:2103.03404.

[6] N. Cammarata. Neural Networks Are Already Clean. Goodfire, 2026. https://already-clean.goodfire.com/

[7] L. Gao. Neural networks are not already clean. LessWrong, 2026. https://www.lesswrong.com/posts/Dkh7pXKjoNWkkxQDz/neural-networks-are-not-already-clean

[8] C. Olah et al. Zoom In: An Introduction to Circuits. Distill, 2020. https://distill.pub/2020/circuits/zoom-in/

[9] M. Lissack. Already Clean, Not Yet Meaningful: One “how” for the question Cammarata has opened. PhilArchive. https://philarchive.org/rec/LISACN

[10] S. Brodsky. Is AI easier to understand than scientists thought? IBM Think, 2026. https://www.ibm.com/think/news/is-ai-easier-to-understand-than-scientists-thought-goodfire-essay

[11] A. Katharopoulos et al. Transformers are RNNs: Fast Autoregressive Transformers with Linear Attention. ICML, 2020. arXiv:2006.16236.

[12] S. Wang et al. Linformer: Self-Attention with Linear Complexity, 2020. arXiv:2006.04768.

[13] Y. Xiong et al. Nyströmformer: A Nyström-Based Algorithm for Approximating Self-Attention. AAAI, 2021. arXiv:2102.03902.

[14] K. Choromanski et al. Rethinking Attention with Performers. ICLR, 2021. arXiv:2009.14794.

[15] H. Peng et al. Random Feature Attention. ICLR, 2021. arXiv:2103.02143.

[16] J. Lu et al. SOFT: Softmax-free Transformer with Linear Complexity. NeurIPS, 2021. arXiv:2110.11945.

[17] R. Child et al. Generating Long Sequences with Sparse Transformers, 2019. arXiv:1904.10509.

[18] N. Kitaev et al. Reformer: The Efficient Transformer. ICLR, 2020. arXiv:2001.04451.

[19] M. Zaheer et al. Big Bird: Transformers for Longer Sequences. NeurIPS, 2020. arXiv:2007.14062.

[20] J. Lee-Thorp et al. FNet: Mixing Tokens with Fourier Transforms. NAACL, 2022. arXiv:2105.03824.

[21] Y. Tay et al. Synthesizer: Rethinking Self-Attention in Transformer Models. ICML, 2021. arXiv:2005.00743.

[22] J. T. H. Wong et al. A3: an Analytical Low-Rank Approximation Framework for Attention, 2025. arXiv:2505.12942.

[23] C. Olsson et al. In-context Learning and Induction Heads. Transformer Circuits Thread, 2022. arXiv:2209.11895.

[24] T. Bricken et al. Towards Monosemanticity: Decomposing Language Models With Dictionary Learning. Transformer Circuits Thread, 2023. https://transformer-circuits.pub/2023/monosemantic-features/index.html

[25] D. Rai et al. A Practical Review of Mechanistic Interpretability for Transformer-Based Language Models, 2024. arXiv:2407.02646.

[26] Z. Yuan et al. ASVD: Activation-aware Singular Value Decomposition for Compressing Large Language Models, 2023. arXiv:2312.05821.

[27] X. Wang et al. SVD-LLM: Truncation-aware Singular Value Decomposition for Large Language Model Compression. ICLR, 2025. arXiv:2403.07378.

[28] Z. Liu et al. Deja Vu: Contextual Sparsity for Efficient LLMs at Inference Time. ICML, 2023. arXiv:2310.17157.

[29] Z. Zhang et al. MoEfication: Transformer Feed-forward Layers are Mixtures of Experts. Findings of ACL, 2022. arXiv:2110.01786.

[30] J.-Y. Lee et al. CATS: Contextually-Aware Thresholding for Sparsity in Large Language Models. COLM, 2024. arXiv:2404.08763.

[31] J. Liu et al. Training-Free Activation Sparsity in Large Language Models. ICLR, 2025. arXiv:2408.14690.

[32] D. Shopkhoev et al. ReplaceMe: Network Simplification via Depth Pruning and Transformer Block Linearization. NeurIPS, 2025. arXiv:2505.02819.

[33] V.-D. Yun et al. Ghosted Layers: Unconstrained Activation Alignment for Recovering Layer-Pruned LLMs. ICML, 2026. arXiv:2605.15491.

[34] M. Yu et al. The Super Weight in Large Language Models. arXiv:2411.07191, 2024.

[35] M. Sun et al. Massive Activations in Large Language Models. COLM, 2024. arXiv:2402.17762.

[36] S. Merity, C. Xiong, J. Bradbury, R. Socher. Pointer Sentinel Mixture Models. ICLR, 2017. arXiv:1609.07843. Набор WikiText: https://huggingface.co/datasets/Salesforce/wikitext

[37] L. Gao et al. The Pile: An 800GB Dataset of Diverse Text for Language Modeling. 2020. arXiv:2101.00027. Подвыборка pile-10k: https://huggingface.co/datasets/NeelNanda/pile-10k

[38] L. Gao et al. A framework for few-shot language model evaluation (lm-evaluation-harness), v0.4. Zenodo, 2023. https://github.com/EleutherAI/lm-evaluation-harness

[39] D. Paperno et al. The LAMBADA dataset: Word prediction requiring a broad discourse context. ACL, 2016.

[40] R. Zellers, A. Holtzman, Y. Bisk, A. Farhadi, Y. Choi. HellaSwag: Can a Machine Really Finish Your Sentence? ACL, 2019.

[41] P. Clark et al. Think you have Solved Question Answering? Try ARC, the AI2 Reasoning Challenge. 2018. arXiv:1803.05457.

[42] Y. Bisk, R. Zellers, R. Le Bras, J. Gao, Y. Choi. PIQA: Reasoning about Physical Commonsense in Natural Language. AAAI, 2020.

[43] K. Sakaguchi, R. Le Bras, C. Bhagavatula, Y. Choi. WinoGrande: An Adversarial Winograd Schema Challenge at Scale. AAAI, 2020.

[44] D. Hendrycks et al. Measuring Massive Multitask Language Understanding. ICLR, 2021. arXiv:2009.03300.